Anexo A7 – Tabelas completas de recuperação

As tabelas reproduzem integralmente os resultados de recuperação das Seções 8.1 a 8.3 do artigo. Todas as métricas variam de 0 a 1, e maior é melhor; valores entre colchetes são intervalos de confiança de 95%. Nas comparações pareadas, a coluna Vitórias A/B conta as consultas em que o primeiro (A) ou o segundo (B) braço da comparação teve o valor maior.

Quadro 1 – Braços de recuperação comparados.

Braço	Descrição
A	Contagem de termos da pergunta presentes no texto.
B	BM25.
C	Busca densa exata.
C′	Busca densa com índice aproximado.
D	Fusão de A e B.
E	Fusão de B e C.

Quadro 2 – Métricas de recuperação.

Métrica	Significado
P@1	Fração das consultas cujo primeiro resultado é relevante.
P@3	Fração relevante dos três primeiros resultados.
R@5	Fração dos itens relevantes encontrada entre os cinco primeiros resultados.
MRR	Média do inverso da posição do primeiro resultado relevante.
nDCG@10	Qualidade da ordenação dos dez primeiros resultados, com mais peso para os relevantes no topo (1 = ordenação ideal).

Desempenho por braço

Tabela 1 – Desempenho de recuperação por braço em C1, unidade de recuperação: documento. Intervalos de confiança de 95% por *bootstrap* sobre as consultas (10 mil reamostragens). A última linha é o teto alcançável de cada métrica: P@k divide por *k*, então uma consulta com um único item relevante limita P@3 a 1/3 mesmo sob ordenação perfeita.

Braço	**P@1**	**P@3**	**R@5**	**MRR**	**nDCG@10**
A, contagem	0,750 [0,500, 0,938]	0,312 [0,250, 0,375]	1,000 [1,000, 1,000]	0,830 [0,669, 0,958]	0,869 [0,748, 0,968]
B, BM25	0,812 [0,625, 1,000]	0,333 [0,250, 0,417]	1,000 [1,000, 1,000]	0,861 [0,715, 1,000]	0,894 [0,783, 0,998]
C, denso exato	0,688 [0,438, 0,875]	0,354 [0,333, 0,396]	1,000 [1,000, 1,000]	0,823 [0,687, 0,938]	0,844 [0,742, 0,944]
C′, denso IVF	0,688 [0,438, 0,875]	0,292 [0,229, 0,333]	0,812 [0,625, 0,969]	0,781 [0,594, 0,938]	0,797 [0,615, 0,945]
D, RRF(A,B)	0,812 [0,625, 1,000]	0,312 [0,250, 0,375]	1,000 [1,000, 1,000]	0,865 [0,719, 1,000]	0,896 [0,787, 0,997]
E, RRF(B,C)	0,812 [0,625, 1,000]	0,333 [0,271, 0,396]	1,000 [1,000, 1,000]	0,880 [0,745, 1,000]	0,890 [0,788, 0,975]
Teto alcançável	1,000	0,375	1,000	—	—

Fonte: elaborado pelo autor.

Tabela 2 – Desempenho de recuperação por braço em C1, unidade de recuperação: seção. Intervalos de confiança de 95% por *bootstrap* sobre as consultas (10 mil reamostragens). A última linha é o teto alcançável de cada métrica: P@k divide por *k*, então uma consulta com um único item relevante limita P@3 a 1/3 mesmo sob ordenação perfeita.

Braço	**P@1**	**P@3**	**R@5**	**MRR**	**nDCG@10**
A, contagem	0,562 [0,312, 0,812]	0,292 [0,187, 0,396]	0,719 [0,531, 0,906]	0,689 [0,499, 0,864]	0,706 [0,521, 0,873]
B, BM25	0,750 [0,500, 0,938]	0,354 [0,271, 0,438]	0,812 [0,625, 0,969]	0,818 [0,646, 0,958]	0,829 [0,665, 0,958]
D, RRF(A,B)	0,562 [0,312, 0,812]	0,354 [0,271, 0,438]	0,812 [0,625, 0,969]	0,707 [0,530, 0,869]	0,729 [0,550, 0,883]
Teto alcançável	1,000	0,458	1,000	—	—

Fonte: elaborado pelo autor.

Variantes de consulta

Tabela 3 – P@1 por variante de consulta em C1, unidade de recuperação: documento. A última coluna é a queda de P@1 da consulta literal para a paráfrase, medida da dependência de casamento lexical de cada braço.

Braço	Literal	Paráfrase	Ruidosa	Queda literal→paráfrase
A, contagem	1,000	0,571	0,750	+0,429
B, BM25	1,000	0,714	0,750	+0,286
C, denso exato	0,600	0,571	1,000	+0,029
C′, denso IVF	0,600	0,714	0,750	−0,114
D, RRF(A,B)	1,000	0,571	1,000	+0,429
E, RRF(B,C)	0,800	0,714	1,000	+0,086

Fonte: elaborado pelo autor.

Tabela 4 – P@1 por variante de consulta em C1, unidade de recuperação: seção. A última coluna é a queda de P@1 da consulta literal para a paráfrase, medida da dependência de casamento lexical de cada braço.

Braço	Literal	Paráfrase	Ruidosa	Queda literal→paráfrase
A, contagem	1,000	0,143	0,750	+0,857
B, BM25	1,000	0,429	1,000	+0,571
D, RRF(A,B)	1,000	0,143	0,750	+0,857

Fonte: elaborado pelo autor.

Consultas negativas e limiar de corte

Tabela 5 – Comportamento em casos negativos (consultas cuja resposta correta é não recuperar nada). Taxa de falso positivo: 0,0 significa reconhecer a ausência de resposta; 1,0 significa responder mesmo assim. Unidade de recuperação: documento.

Braço	Taxa de falso positivo	Itens devolvidos (média)
A, contagem	1,000	5,0
B, BM25	1,000	5,0
C, denso exato	1,000	5,0
C′, denso IVF	1,000	2,5
D, RRF(A,B)	1,000	5,0
E, RRF(B,C)	1,000	5,0

Fonte: elaborado pelo autor.

Tabela 6 – Comportamento em casos negativos (consultas cuja resposta correta é não recuperar nada). Taxa de falso positivo: 0,0 significa reconhecer a ausência de resposta; 1,0 significa responder mesmo assim. Unidade de recuperação: seção.

Braço	Taxa de falso positivo	Itens devolvidos (média)
A, contagem	1,000	19,0
B, BM25	1,000	18,0
D, RRF(A,B)	1,000	19,0

Fonte: elaborado pelo autor.

Tabela 7 – Separabilidade dos escores e efeito de um limiar de corte. A sobreposição é a fração de itens irrelevantes que pontuam acima do menor item relevante; *J* é o índice de Youden no limiar ótimo, valendo 1 para separação perfeita e 0 quando o corte não supera o acaso. A taxa de falso positivo é medida sobre as consultas negativas, cuja resposta correta é não devolver nada.

Braço	Sobrep.	Limiar	*J*	FP sem limiar	FP com limiar
A, contagem	0,782	4,000	0,288	1,000	0,500
B, BM25	0,980	2,127	0,673	1,000	0,500

Fonte: elaborado pelo autor.

Comparações pareadas

Tabela 8 – Comparações pareadas: teste de aleatorização exato sobre as consultas, com correção de Holm para 75 comparações. *n* é o número de consultas em que os dois braços diferem; a última coluna conta em quantas delas cada braço da comparação teve o valor maior. Unidade de recuperação: documento.

Comparação	Métrica	Δ	*n*	*p*	*p* Holm	Vitórias A/B
A, contagem vs B, BM25	P@1	−0,062	1	1,000	1,000	0/1
A, contagem vs B, BM25	P@3	−0,021	3	0,750	1,000	1/2
A, contagem vs B, BM25	R@5	+0,000	0	1,000	1,000	0/0
A, contagem vs B, BM25	MRR	−0,031	4	1,000	1,000	3/1
A, contagem vs B, BM25	nDCG@10	−0,025	5	0,938	1,000	3/2
A, contagem vs C, denso exato	P@1	+0,062	5	1,000	1,000	3/2
A, contagem vs C, denso exato	P@3	−0,042	2	0,500	1,000	0/2
A, contagem vs C, denso exato	R@5	+0,000	0	1,000	1,000	0/0
A, contagem vs C, denso exato	MRR	+0,007	7	0,984	1,000	3/4
A, contagem vs C, denso exato	nDCG@10	+0,025	8	0,727	1,000	4/4
A, contagem vs C′, denso IVF	P@1	+0,062	5	1,000	1,000	3/2
A, contagem vs C′, denso IVF	P@3	+0,021	5	0,750	1,000	3/2
A, contagem vs C′, denso IVF	R@5	+0,188	4	0,125	1,000	4/0
A, contagem vs C′, denso IVF	MRR	+0,049	7	0,656	1,000	4/3
A, contagem vs C′, denso IVF	nDCG@10	+0,071	8	0,492	1,000	5/3
A, contagem vs D, RRF(A,B)	P@1	−0,062	1	1,000	1,000	0/1
A, contagem vs D, RRF(A,B)	P@3	+0,000	2	1,000	1,000	1/1
A, contagem vs D, RRF(A,B)	R@5	+0,000	0	1,000	1,000	0/0
A, contagem vs D, RRF(A,B)	MRR	−0,034	2	0,500	1,000	0/2
A, contagem vs D, RRF(A,B)	nDCG@10	−0,027	4	0,250	1,000	1/3
A, contagem vs E, RRF(B,C)	P@1	−0,062	3	1,000	1,000	1/2

Comparação	Métrica	Δ	*n*	*p*	*p* Holm	Vitórias A/B
A, contagem vs E, RRF(B,C)	P@3	−0,021	3	1,000	1,000	1/2
A, contagem vs E, RRF(B,C)	R@5	+0,000	0	1,000	1,000	0/0
A, contagem vs E, RRF(B,C)	MRR	−0,050	5	0,625	1,000	2/3
A, contagem vs E, RRF(B,C)	nDCG@10	−0,022	7	0,719	1,000	3/4
B, BM25 vs C, denso exato	P@1	+0,125	6	0,688	1,000	4/2
B, BM25 vs C, denso exato	P@3	−0,021	3	1,000	1,000	1/2
B, BM25 vs C, denso exato	R@5	+0,000	0	1,000	1,000	0/0
B, BM25 vs C, denso exato	MRR	+0,039	7	0,734	1,000	4/3
B, BM25 vs C, denso exato	nDCG@10	+0,050	8	0,531	1,000	5/3
B, BM25 vs C′, denso IVF	P@1	+0,125	4	0,625	1,000	3/1
B, BM25 vs C′, denso IVF	P@3	+0,042	6	0,406	1,000	4/2
B, BM25 vs C′, denso IVF	R@5	+0,188	4	0,125	1,000	4/0
B, BM25 vs C′, denso IVF	MRR	+0,080	6	0,438	1,000	4/2
B, BM25 vs C′, denso IVF	nDCG@10	+0,096	7	0,312	1,000	5/2
B, BM25 vs D, RRF(A,B)	P@1	+0,000	2	1,000	1,000	1/1
B, BM25 vs D, RRF(A,B)	P@3	+0,021	3	0,750	1,000	2/1
B, BM25 vs D, RRF(A,B)	R@5	+0,000	0	1,000	1,000	0/0
B, BM25 vs D, RRF(A,B)	MRR	−0,003	4	1,000	1,000	1/3
B, BM25 vs D, RRF(A,B)	nDCG@10	−0,002	5	1,000	1,000	2/3
B, BM25 vs E, RRF(B,C)	P@1	+0,000	2	1,000	1,000	1/1
B, BM25 vs E, RRF(B,C)	P@3	+0,000	2	1,000	1,000	1/1
B, BM25 vs E, RRF(B,C)	R@5	+0,000	0	1,000	1,000	0/0
B, BM25 vs E, RRF(B,C)	MRR	−0,019	3	0,750	1,000	1/2
B, BM25 vs E, RRF(B,C)	nDCG@10	+0,003	5	0,938	1,000	3/2
C, denso exato vs C′, denso IVF	P@1	+0,000	2	1,000	1,000	1/1
C, denso exato vs C′, denso IVF	P@3	+0,062	3	0,250	1,000	3/0
C, denso exato vs C′, denso IVF	R@5	+0,188	4	0,125	1,000	4/0
C, denso exato vs C′, denso IVF	MRR	+0,042	5	0,750	1,000	2/3
C, denso exato vs C′, denso IVF	nDCG@10	+0,046	6	0,625	1,000	2/4
C, denso exato vs D, RRF(A,B)	P@1	−0,125	4	0,625	1,000	1/3
C, denso exato vs D, RRF(A,B)	P@3	+0,042	4	0,625	1,000	3/1
C, denso exato vs D, RRF(A,B)	R@5	+0,000	0	1,000	1,000	0/0
C, denso exato vs D, RRF(A,B)	MRR	−0,042	6	0,688	1,000	3/3
C, denso exato vs D, RRF(A,B)	nDCG@10	−0,052	7	0,469	1,000	3/4
C, denso exato vs E, RRF(B,C)	P@1	−0,125	4	0,625	1,000	1/3
C, denso exato vs E, RRF(B,C)	P@3	+0,021	1	1,000	1,000	1/0
C, denso exato vs E, RRF(B,C)	R@5	+0,000	0	1,000	1,000	0/0
C, denso exato vs E, RRF(B,C)	MRR	−0,057	6	0,562	1,000	2/4
C, denso exato vs E, RRF(B,C)	nDCG@10	−0,047	7	0,469	1,000	2/5
C′, denso IVF vs D, RRF(A,B)	P@1	−0,125	6	0,688	1,000	2/4
C′, denso IVF vs D, RRF(A,B)	P@3	−0,021	5	0,750	1,000	2/3
C′, denso IVF vs D, RRF(A,B)	R@5	−0,188	4	0,125	1,000	0/4
C′, denso IVF vs D, RRF(A,B)	MRR	−0,083	7	0,531	1,000	3/4
C′, denso IVF vs D, RRF(A,B)	nDCG@10	−0,099	8	0,398	1,000	3/5

Comparação	Métrica	Δ	*n*	*p*	*p* Holm	Vitórias A/B
C′, denso IVF vs E, RRF(B,C)	P@1	−0,125	4	0,625	1,000	1/3
C′, denso IVF vs E, RRF(B,C)	P@3	−0,042	4	0,500	1,000	1/3
C′, denso IVF vs E, RRF(B,C)	R@5	−0,188	4	0,125	1,000	0/4
C′, denso IVF vs E, RRF(B,C)	MRR	−0,099	5	0,375	1,000	2/3
C′, denso IVF vs E, RRF(B,C)	nDCG@10	−0,093	6	0,406	1,000	3/3
D, RRF(A,B) vs E, RRF(B,C)	P@1	+0,000	2	1,000	1,000	1/1
D, RRF(A,B) vs E, RRF(B,C)	P@3	−0,021	5	0,938	1,000	2/3
D, RRF(A,B) vs E, RRF(B,C)	R@5	+0,000	0	1,000	1,000	0/0
D, RRF(A,B) vs E, RRF(B,C)	MRR	−0,016	4	0,875	1,000	2/2
D, RRF(A,B) vs E, RRF(B,C)	nDCG@10	+0,006	6	0,906	1,000	4/2

Fonte: elaborado pelo autor.

Tabela 9 – Comparações pareadas: teste de aleatorização exato sobre as consultas, com correção de Holm para 15 comparações. *n* é o número de consultas em que os dois braços diferem; a última coluna conta em quantas delas cada braço da comparação teve o valor maior. Unidade de recuperação: seção.

Comparação	Métrica	Δ	*n*	*p*	*p* Holm	Vitórias A/B
A, contagem vs B, BM25	P@1	−0,188	3	0,250	1,000	0/3
A, contagem vs B, BM25	P@3	−0,062	3	0,250	1,000	0/3
A, contagem vs B, BM25	R@5	−0,094	2	0,500	1,000	0/2
A, contagem vs B, BM25	MRR	−0,130	6	0,156	1,000	1/5
A, contagem vs B, BM25	nDCG@10	−0,123	6	0,062	0,938	1/5
A, contagem vs D, RRF(A,B)	P@1	+0,000	0	1,000	1,000	0/0
A, contagem vs D, RRF(A,B)	P@3	−0,062	3	0,250	1,000	0/3
A, contagem vs D, RRF(A,B)	R@5	−0,094	2	0,500	1,000	0/2
A, contagem vs D, RRF(A,B)	MRR	−0,019	5	0,312	1,000	1/4
A, contagem vs D, RRF(A,B)	nDCG@10	−0,023	4	0,250	1,000	1/3
B, BM25 vs D, RRF(A,B)	P@1	+0,188	3	0,250	1,000	3/0
B, BM25 vs D, RRF(A,B)	P@3	+0,000	0	1,000	1,000	0/0
B, BM25 vs D, RRF(A,B)	R@5	+0,000	0	1,000	1,000	0/0
B, BM25 vs D, RRF(A,B)	MRR	+0,111	5	0,062	0,938	5/0
B, BM25 vs D, RRF(A,B)	nDCG@10	+0,099	5	0,062	0,938	5/0

Fonte: elaborado pelo autor.

Determinismo, índices aproximados e proveniência

Tabela 10 – Estabilidade do ranking do braço denso sob variação de fatores que não são propriedades da consulta. Corpus C1 (5 documentos, 18 consultas). Uma ordenação é considerada estável quando o *hash* SHA-256 da lista completa (identificador e escore) é idêntico em todas as repetições.

Fator variado	Estáveis	Ordenações distintas	Perda de revocação
C (exato), 30 execuções	100%	1	–
C′ (IVF), 30 sementes	0%	4	48,4%
C′ (IVF), 30 ordens de inserção	0%	4	–
C′ (IVF), `probes` de 1 a `lists`	0%	2	–

Fonte: elaborado pelo autor.

Tabela 11 – Índices aproximados do pgvector 0.8.6 sobre *corpora* sintéticos (768 dimensões, 20 consultas). Revocação dos 10 primeiros frente à busca exata e número de consultas cujos 10 primeiros resultados mudaram ao reconstruir o índice 5 vezes sobre os mesmos dados e ao inserir os mesmos vetores em 5 ordens.

Índice	***N***	**Revocação@10**	**Reconstrução**	**Ordem**
IVFFlat, √*N* listas, 1 sonda	1.000	47,7%	20/20	20/20
IVFFlat, recomendação do pgvector	1.000	100,0%	0/20	0/20
HNSW, padrões do pgvector	1.000	100,0%	0/20	0/20
IVFFlat, √*N* listas, 1 sonda	5.000	36,5%	20/20	20/20
IVFFlat, recomendação do pgvector	5.000	100,0%	0/20	0/20
HNSW, padrões do pgvector	5.000	99,0%	2/20	4/20
IVFFlat, √*N* listas, 1 sonda	20.000	25,5%	20/20	20/20
IVFFlat, recomendação do pgvector	20.000	100,0%	0/20	0/20
HNSW, padrões do pgvector	20.000	91,0%	6/20	17/20

Fonte: elaborado pelo autor.

Tabela 12 – Auditabilidade do índice sobre o corpus C1. TPC (taxa de proveniência completa) é a fração de itens cuja origem é resolvível: documento, página, posição sequencial e conteúdo, todos presentes. O recorte por tipo estrutural é deliberado: uma média global esconderia um tipo com proveniência incompleta. Itens de escopo de documento (pares de metadado, que são estatísticas do documento inteiro) são avaliados sem exigência de página, porque não existem em página alguma; os demais tipos permanecem sob o critério estrito.

Tipo estrutural	**Itens**	**Completos**	**TPC**
Trecho	19	19	1,000
Metadado	85	85	1,000
Nó de sumário	26	26	1,000
Página	5	5	1,000
Parágrafo	20	20	1,000
Total	**155**	**155**	**1,000**

Fonte: elaborado pelo autor.