Anexo 7 — Tabelas completas de recuperação

TCC ThingIndex — Charles Eduardo Mello Guimarães — IFPR Palmas

Versão integral das tabelas de recuperação das Seções 8.1 a 8.3 do artigo, convertidas sem alteração dos arquivos `docs/article/tables/*.tex`, que são gerados por script a partir dos CSV de resultados. Cada tabela traz acima a legenda original; leia primeiro a legenda de braços e métricas abaixo.

Legenda

Braços (estratégias de recuperação comparadas)

A
: contagem de termos da pergunta que aparecem no texto

B
: BM25, ranqueamento lexical clássico que pondera termos raros

C
: denso exato: similaridade entre vetores de *embedding*, comparando com todos os itens

C′
: denso com índice aproximado IVF (pgvector), que compara só com parte dos itens

D
: fusão de A e B por RRF (soma de 1/(k + posição) em cada lista)

E
: fusão de B e C por RRF

Métricas (todas de 0 a 1; maior é melhor)

P@1
: o primeiro resultado é relevante? (média sobre as consultas)

P@3
: fração dos 3 primeiros resultados que é relevante

R@5
: fração dos itens relevantes que aparece entre os 5 primeiros

MRR
: média de 1/posição do primeiro resultado relevante (1 = sempre em 1º)

nDCG@10
: qualidade da ordem dos 10 primeiros, premiando relevantes no topo (1 = ordem ideal)

Números entre colchetes são intervalos de confiança de 95%. Vírgula é o separador decimal. Na coluna Vitórias A/B das comparações pareadas, A e B são o primeiro e o segundo braço da comparação, não os braços A e B. A unidade de recuperação diz o que conta como acerto: o documento certo ou a seção certa.

Desempenho por braço

Tabela 7.1 — `retrieval-summary.tex` — unidade de recuperação: documento

Desempenho de recuperação por braço em C1, unidade de recuperação: documento. Intervalos de confiança de 95% por *bootstrap* sobre as consultas (10 mil reamostragens). A última linha é o teto alcançável de cada métrica: P@k divide por *k*, então uma consulta com um único item relevante limita P@3 a 1/3 mesmo sob ordenação perfeita.

Braço	P@1	P@3	R@5	MRR	nDCG@10
A, contagem	0,750 [0,500, 0,938]	0,312 [0,250, 0,375]	1,000 [1,000, 1,000]	0,830 [0,669, 0,958]	0,869 [0,748, 0,968]
B, BM25	0,812 [0,625, 1,000]	0,333 [0,250, 0,417]	1,000 [1,000, 1,000]	0,861 [0,715, 1,000]	0,894 [0,783, 0,998]
C, denso exato	0,688 [0,438, 0,875]	0,354 [0,333, 0,396]	1,000 [1,000, 1,000]	0,823 [0,687, 0,938]	0,844 [0,742, 0,944]
C′, denso IVF	0,688 [0,438, 0,875]	0,292 [0,229, 0,333]	0,812 [0,625, 0,969]	0,781 [0,594, 0,938]	0,797 [0,615, 0,945]
D, RRF(A,B)	0,812 [0,625, 1,000]	0,312 [0,250, 0,375]	1,000 [1,000, 1,000]	0,865 [0,719, 1,000]	0,896 [0,787, 0,997]
E, RRF(B,C)	0,812 [0,625, 1,000]	0,333 [0,271, 0,396]	1,000 [1,000, 1,000]	0,880 [0,745, 1,000]	0,890 [0,788, 0,975]
Teto alcançável	1,000	0,375	1,000	—	—

Tabela 7.2 — `retrieval-summary-section.tex` — unidade de recuperação: seção

Desempenho de recuperação por braço em C1, unidade de recuperação: seção. Intervalos de confiança de 95% por *bootstrap* sobre as consultas (10 mil reamostragens). A última linha é o teto alcançável de cada métrica: P@k divide por *k*, então uma consulta com um único item relevante limita P@3 a 1/3 mesmo sob ordenação perfeita.

Braço	P@1	P@3	R@5	MRR	nDCG@10
A, contagem	0,562 [0,312, 0,812]	0,292 [0,187, 0,396]	0,719 [0,531, 0,906]	0,689 [0,499, 0,864]	0,706 [0,521, 0,873]
B, BM25	0,750 [0,500, 0,938]	0,354 [0,271, 0,438]	0,812 [0,625, 0,969]	0,818 [0,646, 0,958]	0,829 [0,665, 0,958]
D, RRF(A,B)	0,562 [0,312, 0,812]	0,354 [0,271, 0,438]	0,812 [0,625, 0,969]	0,707 [0,530, 0,869]	0,729 [0,550, 0,883]
Teto alcançável	1,000	0,458	1,000	—	—

Variantes de consulta

Tabela 7.3 — `retrieval-variants.tex` — unidade de recuperação: documento

P@1 por variante de consulta em C1, unidade de recuperação: documento. A última coluna é a queda de P@1 da consulta literal para a paráfrase, medida da dependência de casamento lexical de cada braço.

Braço	Literal	Paráfrase	Ruidosa	Queda literal→paráfrase
A, contagem	1,000	0,571	0,750	+0,429
B, BM25	1,000	0,714	0,750	+0,286
C, denso exato	0,600	0,571	1,000	+0,029
C′, denso IVF	0,600	0,714	0,750	−0,114
D, RRF(A,B)	1,000	0,571	1,000	+0,429
E, RRF(B,C)	0,800	0,714	1,000	+0,086

Tabela 7.4 — `retrieval-variants-section.tex` — unidade de recuperação: seção

P@1 por variante de consulta em C1, unidade de recuperação: seção. A última coluna é a queda de P@1 da consulta literal para a paráfrase, medida da dependência de casamento lexical de cada braço.

Braço	Literal	Paráfrase	Ruidosa	Queda literal→paráfrase
A, contagem	1,000	0,143	0,750	+0,857
B, BM25	1,000	0,429	1,000	+0,571
D, RRF(A,B)	1,000	0,143	0,750	+0,857

Consultas negativas e limiar de corte

Tabela 7.5 — `retrieval-negatives.tex` — unidade de recuperação: documento

Comportamento em casos negativos (consultas cuja resposta correta é não recuperar nada). Taxa de falso positivo: 0,0 significa reconhecer a ausência de resposta; 1,0 significa responder mesmo assim.

Braço	Taxa de falso positivo	Itens devolvidos (média)
A, contagem	1,000	5,0
B, BM25	1,000	5,0
C, denso exato	1,000	5,0
C′, denso IVF	1,000	2,5
D, RRF(A,B)	1,000	5,0
E, RRF(B,C)	1,000	5,0

Tabela 7.6 — `retrieval-negatives-section.tex` — unidade de recuperação: seção

Comportamento em casos negativos (consultas cuja resposta correta é não recuperar nada). Taxa de falso positivo: 0,0 significa reconhecer a ausência de resposta; 1,0 significa responder mesmo assim.

Braço	Taxa de falso positivo	Itens devolvidos (média)
A, contagem	1,000	19,0
B, BM25	1,000	18,0
D, RRF(A,B)	1,000	19,0

Tabela 7.7 — `threshold.tex`

Separabilidade dos escores e efeito de um limiar de corte. A sobreposição é a fração de itens irrelevantes que pontuam acima do menor item relevante; *J* é o índice de Youden no limiar ótimo, valendo 1 para separação perfeita e 0 quando o corte não supera o acaso. A taxa de falso positivo é medida sobre as consultas negativas, cuja resposta correta é não devolver nada.

Braço	Sobrep.	Limiar	*J*	FP sem limiar	FP com limiar
A, contagem	0,782	4,000	0,288	1,000	0,500
B, BM25	0,980	2,127	0,673	1,000	0,500

Comparações pareadas

Tabela 7.8 — `retrieval-significance.tex` — unidade de recuperação: documento

Comparações pareadas: teste de aleatorização exato sobre as consultas, com correção de Holm para 75 comparações. *n* é o número de consultas em que os dois braços diferem; a última coluna conta em quantas delas cada braço da comparação teve o valor maior.

Comparação	Métrica	Δ	*n*	*p*	*p* Holm	Vitórias A/B
A, contagem vs B, BM25	P@1	−0,062	1	1,000	1,000	0/1
A, contagem vs B, BM25	P@3	−0,021	3	0,750	1,000	1/2
A, contagem vs B, BM25	R@5	+0,000	0	1,000	1,000	0/0
A, contagem vs B, BM25	MRR	−0,031	4	1,000	1,000	3/1
A, contagem vs B, BM25	nDCG@10	−0,025	5	0,938	1,000	3/2
A, contagem vs C, denso exato	P@1	+0,062	5	1,000	1,000	3/2
A, contagem vs C, denso exato	P@3	−0,042	2	0,500	1,000	0/2
A, contagem vs C, denso exato	R@5	+0,000	0	1,000	1,000	0/0
A, contagem vs C, denso exato	MRR	+0,007	7	0,984	1,000	3/4
A, contagem vs C, denso exato	nDCG@10	+0,025	8	0,727	1,000	4/4
A, contagem vs C′, denso IVF	P@1	+0,062	5	1,000	1,000	3/2
A, contagem vs C′, denso IVF	P@3	+0,021	5	0,750	1,000	3/2
A, contagem vs C′, denso IVF	R@5	+0,188	4	0,125	1,000	4/0
A, contagem vs C′, denso IVF	MRR	+0,049	7	0,656	1,000	4/3
A, contagem vs C′, denso IVF	nDCG@10	+0,071	8	0,492	1,000	5/3
A, contagem vs D, RRF(A,B)	P@1	−0,062	1	1,000	1,000	0/1
A, contagem vs D, RRF(A,B)	P@3	+0,000	2	1,000	1,000	1/1
A, contagem vs D, RRF(A,B)	R@5	+0,000	0	1,000	1,000	0/0
A, contagem vs D, RRF(A,B)	MRR	−0,034	2	0,500	1,000	0/2
A, contagem vs D, RRF(A,B)	nDCG@10	−0,027	4	0,250	1,000	1/3
A, contagem vs E, RRF(B,C)	P@1	−0,062	3	1,000	1,000	1/2
A, contagem vs E, RRF(B,C)	P@3	−0,021	3	1,000	1,000	1/2
A, contagem vs E, RRF(B,C)	R@5	+0,000	0	1,000	1,000	0/0
A, contagem vs E, RRF(B,C)	MRR	−0,050	5	0,625	1,000	2/3
A, contagem vs E, RRF(B,C)	nDCG@10	−0,022	7	0,719	1,000	3/4
B, BM25 vs C, denso exato	P@1	+0,125	6	0,688	1,000	4/2
B, BM25 vs C, denso exato	P@3	−0,021	3	1,000	1,000	1/2
B, BM25 vs C, denso exato	R@5	+0,000	0	1,000	1,000	0/0
B, BM25 vs C, denso exato	MRR	+0,039	7	0,734	1,000	4/3
B, BM25 vs C, denso exato	nDCG@10	+0,050	8	0,531	1,000	5/3
B, BM25 vs C′, denso IVF	P@1	+0,125	4	0,625	1,000	3/1
B, BM25 vs C′, denso IVF	P@3	+0,042	6	0,406	1,000	4/2
B, BM25 vs C′, denso IVF	R@5	+0,188	4	0,125	1,000	4/0
B, BM25 vs C′, denso IVF	MRR	+0,080	6	0,438	1,000	4/2
B, BM25 vs C′, denso IVF	nDCG@10	+0,096	7	0,312	1,000	5/2
B, BM25 vs D, RRF(A,B)	P@1	+0,000	2	1,000	1,000	1/1

Comparação	Métrica	Δ	*n*	*p*	*p* Holm	Vitórias A/B
B, BM25 vs D, RRF(A,B)	P@3	+0,021	3	0,750	1,000	2/1
B, BM25 vs D, RRF(A,B)	R@5	+0,000	0	1,000	1,000	0/0
B, BM25 vs D, RRF(A,B)	MRR	−0,003	4	1,000	1,000	1/3
B, BM25 vs D, RRF(A,B)	nDCG@10	−0,002	5	1,000	1,000	2/3
B, BM25 vs E, RRF(B,C)	P@1	+0,000	2	1,000	1,000	1/1
B, BM25 vs E, RRF(B,C)	P@3	+0,000	2	1,000	1,000	1/1
B, BM25 vs E, RRF(B,C)	R@5	+0,000	0	1,000	1,000	0/0
B, BM25 vs E, RRF(B,C)	MRR	−0,019	3	0,750	1,000	1/2
B, BM25 vs E, RRF(B,C)	nDCG@10	+0,003	5	0,938	1,000	3/2
C, denso exato vs C′, denso IVF	P@1	+0,000	2	1,000	1,000	1/1
C, denso exato vs C′, denso IVF	P@3	+0,062	3	0,250	1,000	3/0
C, denso exato vs C′, denso IVF	R@5	+0,188	4	0,125	1,000	4/0
C, denso exato vs C′, denso IVF	MRR	+0,042	5	0,750	1,000	2/3
C, denso exato vs C′, denso IVF	nDCG@10	+0,046	6	0,625	1,000	2/4
C, denso exato vs D, RRF(A,B)	P@1	−0,125	4	0,625	1,000	1/3
C, denso exato vs D, RRF(A,B)	P@3	+0,042	4	0,625	1,000	3/1
C, denso exato vs D, RRF(A,B)	R@5	+0,000	0	1,000	1,000	0/0
C, denso exato vs D, RRF(A,B)	MRR	−0,042	6	0,688	1,000	3/3
C, denso exato vs D, RRF(A,B)	nDCG@10	−0,052	7	0,469	1,000	3/4
C, denso exato vs E, RRF(B,C)	P@1	−0,125	4	0,625	1,000	1/3
C, denso exato vs E, RRF(B,C)	P@3	+0,021	1	1,000	1,000	1/0
C, denso exato vs E, RRF(B,C)	R@5	+0,000	0	1,000	1,000	0/0
C, denso exato vs E, RRF(B,C)	MRR	−0,057	6	0,562	1,000	2/4
C, denso exato vs E, RRF(B,C)	nDCG@10	−0,047	7	0,469	1,000	2/5
C′, denso IVF vs D, RRF(A,B)	P@1	−0,125	6	0,688	1,000	2/4
C′, denso IVF vs D, RRF(A,B)	P@3	−0,021	5	0,750	1,000	2/3
C′, denso IVF vs D, RRF(A,B)	R@5	−0,188	4	0,125	1,000	0/4
C′, denso IVF vs D, RRF(A,B)	MRR	−0,083	7	0,531	1,000	3/4
C′, denso IVF vs D, RRF(A,B)	nDCG@10	−0,099	8	0,398	1,000	3/5
C′, denso IVF vs E, RRF(B,C)	P@1	−0,125	4	0,625	1,000	1/3
C′, denso IVF vs E, RRF(B,C)	P@3	−0,042	4	0,500	1,000	1/3
C′, denso IVF vs E, RRF(B,C)	R@5	−0,188	4	0,125	1,000	0/4
C′, denso IVF vs E, RRF(B,C)	MRR	−0,099	5	0,375	1,000	2/3
C′, denso IVF vs E, RRF(B,C)	nDCG@10	−0,093	6	0,406	1,000	3/3
D, RRF(A,B) vs E, RRF(B,C)	P@1	+0,000	2	1,000	1,000	1/1
D, RRF(A,B) vs E, RRF(B,C)	P@3	−0,021	5	0,938	1,000	2/3
D, RRF(A,B) vs E, RRF(B,C)	R@5	+0,000	0	1,000	1,000	0/0
D, RRF(A,B) vs E, RRF(B,C)	MRR	−0,016	4	0,875	1,000	2/2
D, RRF(A,B) vs E, RRF(B,C)	nDCG@10	+0,006	6	0,906	1,000	4/2

Tabela 7.9 — `retrieval-significance-section.tex` — unidade de recuperação: seção

Comparações pareadas: teste de aleatorização exato sobre as consultas, com correção de Holm para 15 comparações. *n* é o número de consultas em que os dois braços diferem; a última coluna conta em quantas delas cada braço da comparação teve o valor maior.

Comparação	Métrica	Δ	*n*	*p*	*p* Holm	Vitórias A/B
A, contagem vs B, BM25	P@1	−0,188	3	0,250	1,000	0/3
A, contagem vs B, BM25	P@3	−0,062	3	0,250	1,000	0/3
A, contagem vs B, BM25	R@5	−0,094	2	0,500	1,000	0/2
A, contagem vs B, BM25	MRR	−0,130	6	0,156	1,000	1/5
A, contagem vs B, BM25	nDCG@10	−0,123	6	0,062	0,938	1/5
A, contagem vs D, RRF(A,B)	P@1	+0,000	0	1,000	1,000	0/0
A, contagem vs D, RRF(A,B)	P@3	−0,062	3	0,250	1,000	0/3
A, contagem vs D, RRF(A,B)	R@5	−0,094	2	0,500	1,000	0/2
A, contagem vs D, RRF(A,B)	MRR	−0,019	5	0,312	1,000	1/4
A, contagem vs D, RRF(A,B)	nDCG@10	−0,023	4	0,250	1,000	1/3
B, BM25 vs D, RRF(A,B)	P@1	+0,188	3	0,250	1,000	3/0
B, BM25 vs D, RRF(A,B)	P@3	+0,000	0	1,000	1,000	0/0
B, BM25 vs D, RRF(A,B)	R@5	+0,000	0	1,000	1,000	0/0
B, BM25 vs D, RRF(A,B)	MRR	+0,111	5	0,062	0,938	5/0
B, BM25 vs D, RRF(A,B)	nDCG@10	+0,099	5	0,062	0,938	5/0

Determinismo, índices aproximados e proveniência

Tabela 7.10 — `dense-determinism.tex`

Estabilidade do ranking do braço denso sob variação de fatores que não são propriedades da consulta. Corpus C1 (5 documentos, 18 consultas). Uma ordenação é considerada estável quando o *hash* SHA-256 da lista completa (identificador e escore) é idêntico em todas as repetições.

Fator variado	Estáveis	Ordenações distintas	Perda de revocação
C (exato), 30 execuções	100%	1	–
C′ (IVF), 30 sementes	0%	4	48,4%
C′ (IVF), 30 ordens de inserção	0%	4	–
C′ (IVF), `probes` de 1 a `lists`	0%	2	–

Tabela 7.11 — `ann-pgvector.tex`

Índices aproximados do pgvector 0.8.6 sobre *corpora* sintéticos (768 dimensões, 20 consultas). Revocação dos 10 primeiros frente à busca exata e número de consultas cujos 10 primeiros resultados mudaram ao reconstruir o índice 5 vezes sobre os mesmos dados e ao inserir os mesmos vetores em 5 ordens.

Índice	*N*	Revocação@10	Reconstrução	Ordem
IVFFlat, √*N* listas, 1 sonda	1.000	47,7%	20/20	20/20
IVFFlat, recomendação do pgvector	1.000	100,0%	0/20	0/20
HNSW, padrões do pgvector	1.000	100,0%	0/20	0/20
IVFFlat, √*N* listas, 1 sonda	5.000	36,5%	20/20	20/20
IVFFlat, recomendação do pgvector	5.000	100,0%	0/20	0/20
HNSW, padrões do pgvector	5.000	99,0%	2/20	4/20
IVFFlat, √*N* listas, 1 sonda	20.000	25,5%	20/20	20/20
IVFFlat, recomendação do pgvector	20.000	100,0%	0/20	0/20
HNSW, padrões do pgvector	20.000	91,0%	6/20	17/20

Tabela 7.12 — `provenance.tex`

Auditabilidade do índice sobre o corpus C1. TPC (taxa de proveniência completa) é a fração de itens cuja origem é resolvível: documento, página, posição sequencial e conteúdo, todos presentes. O recorte por tipo estrutural é deliberado: uma média global esconderia um tipo com proveniência incompleta. Itens de escopo de documento (pares de metadado, que são estatísticas do documento inteiro) são avaliados sem exigência de página, porque não existem em página alguma; os demais tipos permanecem sob o critério estrito.

Tipo estrutural	Itens	Completos	TPC
Trecho	19	19	1,000
Metadado	85	85	1,000
Nó de sumário	26	26	1,000
Página	5	5	1,000
Parágrafo	20	20	1,000
Total	**155**	**155**	**1,000**