Anexo A7 – Tabelas completas de recuperação

Como ler este anexo

Este anexo traz todos os números do primeiro experimento do artigo (Seções 8.1 a 8.4). O experimento comparou formas diferentes de encontrar, entre vários textos, o trecho que responde a uma pergunta. Para isso, usou um conjunto pequeno, chamado C1 no artigo: 5 textos curtos escritos pelo autor (jurídico, contratual e normativo) e 18 perguntas, 16 com resposta num dos textos e 2 sem resposta em nenhum. Como o autor escreveu os textos, sabe-se de antemão qual é o texto certo de cada pergunta, e dá para contar quantas vezes cada forma de busca o encontrou. Cada forma de busca testada é chamada de *braço* do experimento. As notas vão de 0 a 1, e maior é melhor: 0,750 quer dizer 75%. As medições foram feitas de dois jeitos: escolhendo entre os 5 textos inteiros (unidade documento), tarefa fácil, em que um sorteio já acertaria o 1º lugar cerca de 20% das vezes; e escolhendo entre as 19 seções em que os textos foram divididos (unidade seção), tarefa mais difícil e mais parecida com o que o sistema faz. Por seção, só os braços de busca por palavras foram medidos, porque a busca por significado (braços C, C′ e E do Quadro 1) foi preparada por texto inteiro.

Quadro 1 – Braços comparados.

Braço	Nome	Como funciona
A	contagem de palavras	Conta quantas palavras da pergunta aparecem no texto; quanto mais palavras em comum, mais alto o texto fica na lista. Era a busca da versão antiga do ThingIndex.
B	BM25	Busca por palavras usada hoje pelo sistema. Também compara palavras, mas com uma fórmula clássica que dá mais peso às palavras raras, que identificam melhor o assunto, e impede que uma palavra repetida muitas vezes domine a nota.
C	busca por significado (vetores), exata	Um modelo de linguagem transforma a pergunta e cada texto numa lista de números, chamada vetor, que representa o sentido; textos de sentido parecido ficam com vetores próximos, mesmo sem palavras em comum. “Exata” quer dizer que a pergunta é comparada com todos os textos.
C′	busca por significado com índice aproximado	Os mesmos vetores de C, guardados num índice aproximado: os vetores são separados em grupos (gavetas) e cada busca abre só algumas delas. É mais rápido em acervos grandes, mas pode deixar o texto certo de fora.
D	combinação de A e B	Junta as listas de A e de B numa só: cada texto ganha pontos conforme a posição que ocupou em cada lista (o método se chama RRF).
E	combinação de B e C	Igual a D, mas juntando a lista da busca por palavras (B) com a da busca por significado (C).

Quadro 2 – Medidas usadas nas tabelas.

Medida	**O que responde**	**Como ler**
P@1	Em que fração das perguntas o 1º resultado era o texto certo?	0,750 = em 3 de cada 4 perguntas, o 1º resultado era o certo.
P@3	Dos 3 primeiros resultados, que fração era certa?	Como quase toda pergunta tem um só texto certo, mesmo uma busca perfeita teria 1 certo em 3 (0,333). Por isso as tabelas trazem a linha “máximo possível”.
R@5	O texto certo apareceu entre os 5 primeiros resultados?	1,000 = em todas as perguntas, o certo estava entre os 5 primeiros.
MRR	Quão perto do topo veio o texto certo?	1º lugar vale 1; 2º vale 0,5; 3º vale 0,33; e assim por diante. O MRR é a média dessas notas: se numa pergunta o certo veio em 1º e noutra em 2º, o MRR é (1 + 0,5) ÷ 2 = 0,75.
nDCG@10	Parecido com o MRR, mas olhando os 10 primeiros resultados.	Dá mais crédito a quem põe os textos certos no topo; 1 = ordem ideal.
Intervalo de confiança de 95%	Os números entre colchetes, abaixo de cada nota: a faixa onde o valor real provavelmente está.	0,750 com [0,500, 0,938]: com tão poucas perguntas, o valor real pode estar em qualquer ponto dessa faixa. Se as faixas de dois braços se sobrepõem, não dá para dizer que um é melhor. A faixa foi calculada sorteando as perguntas 10 mil vezes (técnica chamada *bootstrap*).
Valor-p	Qual é a chance de a diferença entre dois braços ser só acaso?	Abaixo de 0,05, costuma-se dizer que a diferença não é acaso.
Falso positivo	Devolver resultados para uma pergunta que não tem resposta em nenhum texto.	Taxa 1,000 = devolveu resultados em todas as perguntas sem resposta; 0,000 = reconheceu todas.
Limiar	Nota mínima: resultados com nota abaixo dela são descartados.	Serve para tentar fazer a busca devolver “nada” quando não há resposta.
Índice de Youden (*J*)	Quão bem um limiar separa os textos certos dos errados.	1 = separa perfeitamente; 0 = não é melhor que o acaso.

1. Desempenho de cada braço

Tabela 1 – Desempenho de cada braço escolhendo entre os 5 textos inteiros (unidade: documento). Abaixo de cada nota, entre colchetes, o intervalo de confiança de 95%. A última linha é o máximo possível de cada medida.

Braço	P@1 1º é o certo	P@3 certos nos 3 primeiros	R@5 certo nos 5 primeiros	MRR posição do certo	nDCG@10 ordem dos 10 primeiros
A – contagem de palavras	0,750 [0,500, 0,938]	0,312 [0,250, 0,375]	1,000 [1,000, 1,000]	0,830 [0,669, 0,958]	0,869 [0,748, 0,968]
B – BM25	0,812 [0,625, 1,000]	0,333 [0,250, 0,417]	1,000 [1,000, 1,000]	0,861 [0,715, 1,000]	0,894 [0,783, 0,998]
C – significado, exata	0,688 [0,438, 0,875]	0,354 [0,333, 0,396]	1,000 [1,000, 1,000]	0,823 [0,687, 0,938]	0,844 [0,742, 0,944]
C′ – significado, aproximada	0,688 [0,438, 0,875]	0,292 [0,229, 0,333]	0,812 [0,625, 0,969]	0,781 [0,594, 0,938]	0,797 [0,615, 0,945]
D – combinação de A e B	0,812 [0,625, 1,000]	0,312 [0,250, 0,375]	1,000 [1,000, 1,000]	0,865 [0,719, 1,000]	0,896 [0,787, 0,997]
E – combinação de B e C	0,812 [0,625, 1,000]	0,333 [0,271, 0,396]	1,000 [1,000, 1,000]	0,880 [0,745, 1,000]	0,890 [0,788, 0,975]
Máximo possível	1,000	0,375	1,000	—	—

Tabela 2 – Desempenho de cada braço escolhendo entre as 19 seções (unidade: seção). Mesmo formato da tabela anterior. Só os braços de busca por palavras foram medidos.

Braço	P@1 1º é o certo	P@3 certos nos 3 primeiros	R@5 certo nos 5 primeiros	MRR posição do certo	nDCG@10 ordem dos 10 primeiros
A – contagem de palavras	0,562 [0,312, 0,812]	0,292 [0,187, 0,396]	0,719 [0,531, 0,906]	0,689 [0,499, 0,864]	0,706 [0,521, 0,873]
B – BM25	0,750 [0,500, 0,938]	0,354 [0,271, 0,438]	0,812 [0,625, 0,969]	0,818 [0,646, 0,958]	0,829 [0,665, 0,958]
D – combinação de A e B	0,562 [0,312, 0,812]	0,354 [0,271, 0,438]	0,812 [0,625, 0,969]	0,707 [0,530, 0,869]	0,729 [0,550, 0,883]
Máximo possível	1,000	0,458	1,000	—	—

O que estas tabelas mostram: Escolhendo entre os textos inteiros, o BM25 (B) e as duas combinações (D e E) tiveram as notas mais altas, com nDCG@10 de 0,890 a 0,896, seguidos da contagem de palavras (0,869), da busca por significado exata (0,844) e da aproximada (0,797); a combinação E teve o maior MRR (0,880). Mas as faixas entre colchetes se sobrepõem bastante, e com só 5 textos a tarefa é fácil demais. Escolhendo entre seções, a diferença aparece: o 1º resultado foi o certo em 0,562 das perguntas com a contagem de palavras e em 0,750 com o BM25, e o certo apareceu entre os 5 primeiros em 0,719 e 0,812. Esse resultado levou o sistema a trocar a contagem de palavras pelo BM25.

2. Perguntas com as palavras do texto ou com outras palavras

As perguntas são de três tipos: *literal* (usa as mesmas palavras do texto), *paráfrase* (pede a mesma coisa com outras palavras) e *ruidosa* (com erros de digitação e sem acentos). As tabelas mostram a P@1, isto é, em que fração das perguntas de cada tipo o 1º resultado era o certo.

Tabela 3 – P@1 por tipo de pergunta (unidade: documento). A última coluna é quanto a nota cai da pergunta literal para a paráfrase: quanto maior a queda, mais o braço depende de a pergunta usar as mesmas palavras do texto.

Braço	Literal	Paráfrase	Ruidosa	Queda da literal para a paráfrase
A – contagem de palavras	1,000	0,571	0,750	+0,429
B – BM25	1,000	0,714	0,750	+0,286
C – significado, exata	0,600	0,571	1,000	+0,029
C′ – significado, aproximada	0,600	0,714	0,750	−0,114
D – combinação de A e B	1,000	0,571	1,000	+0,429
E – combinação de B e C	0,800	0,714	1,000	+0,086

Tabela 4 – P@1 por tipo de pergunta (unidade: seção). Mesmo formato da tabela anterior.

Braço	Literal	Paráfrase	Ruidosa	Queda da literal para a paráfrase
A – contagem de palavras	1,000	0,143	0,750	+0,857
B – BM25	1,000	0,429	1,000	+0,571
D – combinação de A e B	1,000	0,143	0,750	+0,857

O que estas tabelas mostram: As buscas por palavras (A, B e D) acertaram todas as perguntas literais e caíram nas paráfrases; a queda foi maior na contagem de palavras (0,429) que no BM25 (0,286). A busca por significado quase não depende das palavras da pergunta (queda de 0,029 em C), mas acertou menos as literais (0,600). Uma queda negativa, como a de C′, quer dizer que a paráfrase foi melhor que a literal. Por seção, a dependência das palavras cresce: a contagem cai 0,857 e acerta só 14% das paráfrases (0,143).

3. Perguntas sem resposta

Duas das 18 perguntas não têm resposta em nenhum dos 5 textos. O certo, nelas, seria a busca não devolver nada.

Tabela 5 – Perguntas sem resposta (unidade: documento): com que frequência cada braço devolveu resultados mesmo assim (taxa de falso positivo) e quantos resultados devolveu, em média. 0,000 seria reconhecer que não há resposta; 1,000 é devolver resultados sempre.

Braço	Taxa de falso positivo	Resultados devolvidos (média)
A – contagem de palavras	1,000	5,0
B – BM25	1,000	5,0
C – significado, exata	1,000	5,0
C′ – significado, aproximada	1,000	2,5
D – combinação de A e B	1,000	5,0
E – combinação de B e C	1,000	5,0

Tabela 6 – Perguntas sem resposta (unidade: seção). Mesmo formato da tabela anterior.

Braço	Taxa de falso positivo	Resultados devolvidos (média)
A – contagem de palavras	1,000	19,0
B – BM25	1,000	18,0
D – combinação de A e B	1,000	19,0

Tabela 7 – Tentativa de usar uma nota mínima (limiar) para descartar resultados. Sobreposição: fração dos textos errados que tiraram nota maior que o texto certo de nota mais baixa (quanto maior, mais misturadas estão as notas de certos e errados). Limiar: a melhor nota mínima encontrada. *J*: índice de Youden nesse limiar. As duas últimas colunas são a taxa de falso positivo sem e com o limiar.

Braço	Sobreposição	Limiar	*J*	Falso positivo sem limiar	Falso positivo com limiar
A – contagem de palavras	0,782	4,000	0,288	1,000	0,500
B – BM25	0,980	2,127	0,673	1,000	0,500

O que estas tabelas mostram: Todos os braços devolveram resultados nas duas perguntas sem resposta (taxa 1,000). Na busca por palavras, qualquer palavra em comum já dá nota positiva, e as notas de textos certos e errados se misturam (sobreposição de 0,782 e 0,980). C′ devolveu menos resultados (2,5 em média) porque só procura numa parte dos textos, mas também não deixou de responder. Mesmo com o melhor limiar, a taxa só cai para 0,500: uma das duas perguntas continua recebendo resultados. A nota da busca, portanto, não serve para decidir que não há resposta; no sistema completo, quem reconhece a falta de resposta é o modelo de linguagem, ao redigir a resposta (Seção 8.2 do artigo).

4. Estabilidade: a mesma pergunta traz sempre a mesma lista?

Um requisito do sistema é que a mesma pergunta traga sempre as mesmas fontes, na mesma ordem. No índice aproximado, os vetores são distribuídos em gavetas por um sorteio, e cada busca abre algumas delas; o sorteio, a ordem em que os textos são inseridos e o número de gavetas abertas podem mudar o resultado. O pgvector, extensão do banco PostgreSQL usada pelo sistema para guardar vetores, oferece dois tipos de índice aproximado: o IVFFlat, que usa gavetas, e o HNSW, que liga cada vetor aos seus vizinhos mais próximos e procura caminhando por essas ligações.

Tabela 8 – Estabilidade da busca por significado em C1 (5 textos, 18 perguntas). Uma pergunta é estável quando a lista completa de resultados, com as notas, sai idêntica em todas as repetições (conferido por uma impressão digital da lista, o *hash* SHA-256).

O que foi variado	Perguntas estáveis	Listas diferentes obtidas	Resultados perdidos frente à busca exata
C (exata), repetida 30 vezes	100%	1	–
C′ (aproximada), 30 sorteios diferentes das gavetas	0%	4	48,4%
C′ (aproximada), textos inseridos em 30 ordens	0%	4	–
C′ (aproximada), abrindo de 1 gaveta até todas	0%	2	–

Tabela 9 – Índices aproximados do pgvector (versão 0.8.6) com 1.000, 5.000 e 20.000 vetores sintéticos (768 números cada) e 20 perguntas. √*N* gavetas: tantas gavetas quanto a raiz quadrada do número de vetores. Revocação nos 10 primeiros: fração dos 10 primeiros resultados da busca exata que o índice também encontrou. As duas últimas colunas contam em quantas das 20 perguntas os 10 primeiros resultados mudaram ao reconstruir o índice 5 vezes sobre os mesmos dados e ao inserir os mesmos vetores em 5 ordens diferentes.

Índice	**Vetores (*N*)**	**Revocação nos 10 primeiros**	**Mudaram ao reconstruir**	**Mudaram ao trocar a ordem**
IVFFlat, √*N* gavetas, 1 aberta por busca	1.000	47,7%	20/20	20/20
IVFFlat, configuração recomendada	1.000	100,0%	0/20	0/20
HNSW, configuração padrão	1.000	100,0%	0/20	0/20
IVFFlat, √*N* gavetas, 1 aberta por busca	5.000	36,5%	20/20	20/20
IVFFlat, configuração recomendada	5.000	100,0%	0/20	0/20
HNSW, configuração padrão	5.000	99,0%	2/20	4/20
IVFFlat, √*N* gavetas, 1 aberta por busca	20.000	25,5%	20/20	20/20
IVFFlat, configuração recomendada	20.000	100,0%	0/20	0/20
HNSW, configuração padrão	20.000	91,0%	6/20	17/20

O que estas tabelas mostram: A busca exata por significado deu a mesma lista nas 30 repetições (a contagem de palavras, o BM25 e a combinação dos dois também, como relata a Seção 8.3 do artigo). O índice aproximado C′, configurado com muitas gavetas e só uma aberta por busca, mudou de resultado com o sorteio e com a ordem de inserção, e perdeu em média 48,4% dos resultados da busca exata. A segunda tabela mostra que isso depende da configuração: na configuração recomendada, o IVFFlat deu sempre o mesmo resultado da busca exata; o HNSW foi exato com 1.000 vetores e, com 20.000, encontrou 91,0% dos resultados, e 6 das 20 perguntas mudaram ao reconstruir o índice e 17 ao trocar a ordem. A estabilidade, portanto, não é uma vantagem exclusiva da busca por palavras.

5. Origem de cada unidade guardada no banco

Ao indexar um documento, o sistema guarda no banco unidades de vários tipos: páginas, parágrafos, trechos (os pedaços de texto citados como fonte), itens do sumário e metadados (estatísticas do documento inteiro, como o número de parágrafos). A taxa de proveniência completa (TPC) é a fração dessas unidades cuja origem está inteira no banco: documento, página, posição e conteúdo.

Tabela 10 – TPC por tipo de unidade, em C1. Os metadados não estão em página nenhuma e por isso são avaliados sem exigência de página; os demais tipos precisam ter página.

Tipo de unidade	Unidades	Com origem completa	TPC
Trecho	19	19	1,000
Metadado	85	85	1,000
Nó de sumário	26	26	1,000
Página	5	5	1,000
Parágrafo	20	20	1,000
Total	**155**	**155**	**1,000**

O que esta tabela mostra: As 155 unidades guardadas têm origem completa (TPC 1,000). Dois cuidados: C1 é texto sem paginação, então a tabela mostra que o sistema grava a origem, e não que a página esteja certa; e a primeira medição deu 0,329, valor que subiu depois de acrescentar a página aos trechos (defeito corrigido) e de declarar que os metadados pertencem ao documento inteiro (ajuste da medida), como detalha a Seção 8.4 do artigo.

6. Comparações de dois em dois: as diferenças são acaso?

Cada linha compara dois braços numa medida. Como as tabelas são longas, os braços aparecem só pela letra (Quadro 1). **Δ (diferença)**: nota do primeiro braço menos a do segundo; positiva, o primeiro foi melhor. ***n***: em quantas perguntas os dois braços tiveram resultado diferente. **Valor-p**: chance de a diferença ser acaso, calculada por um teste que troca ao acaso, pergunta a pergunta, os resultados dos dois braços e vê com que frequência surge uma diferença tão grande. **Valor-p corrigido (Holm)**: o mesmo valor ajustado porque foram feitas muitas comparações ao mesmo tempo (75 por documento e 15 por seção); quanto mais comparações, maior a chance de alguma parecer diferente por sorte, e a correção compensa isso. É este o valor a ler. **Vitórias**: em quantas das *n* perguntas o primeiro e o segundo braço tiveram a nota maior.

Tabela 11 – Comparações entre todos os pares de braços (unidade: documento).

Comparação	Medida	Δ (diferença)	*n*	valor-p	valor-p corrigido (Holm)	Vitórias (1º/2º)
A × B	P@1	−0,062	1	1,000	1,000	0/1
A × B	P@3	−0,021	3	0,750	1,000	1/2
A × B	R@5	+0,000	0	1,000	1,000	0/0
A × B	MRR	−0,031	4	1,000	1,000	3/1
A × B	nDCG@10	−0,025	5	0,938	1,000	3/2
A × C	P@1	+0,062	5	1,000	1,000	3/2
A × C	P@3	−0,042	2	0,500	1,000	0/2
A × C	R@5	+0,000	0	1,000	1,000	0/0
A × C	MRR	+0,007	7	0,984	1,000	3/4
A × C	nDCG@10	+0,025	8	0,727	1,000	4/4
A × C′	P@1	+0,062	5	1,000	1,000	3/2
A × C′	P@3	+0,021	5	0,750	1,000	3/2
A × C′	R@5	+0,188	4	0,125	1,000	4/0
A × C′	MRR	+0,049	7	0,656	1,000	4/3
A × C′	nDCG@10	+0,071	8	0,492	1,000	5/3
A × D	P@1	−0,062	1	1,000	1,000	0/1
A × D	P@3	+0,000	2	1,000	1,000	1/1

Comparação	Medida	Δ (diferença)	*n*	valor-p	valor-p corrigido (Holm)	Vitórias (1º/2º)
A × D	R@5	+0,000	0	1,000	1,000	0/0
A × D	MRR	−0,034	2	0,500	1,000	0/2
A × D	nDCG@10	−0,027	4	0,250	1,000	1/3
A × E	P@1	−0,062	3	1,000	1,000	1/2
A × E	P@3	−0,021	3	1,000	1,000	1/2
A × E	R@5	+0,000	0	1,000	1,000	0/0
A × E	MRR	−0,050	5	0,625	1,000	2/3
A × E	nDCG@10	−0,022	7	0,719	1,000	3/4
B × C	P@1	+0,125	6	0,688	1,000	4/2
B × C	P@3	−0,021	3	1,000	1,000	1/2
B × C	R@5	+0,000	0	1,000	1,000	0/0
B × C	MRR	+0,039	7	0,734	1,000	4/3
B × C	nDCG@10	+0,050	8	0,531	1,000	5/3
B × C′	P@1	+0,125	4	0,625	1,000	3/1
B × C′	P@3	+0,042	6	0,406	1,000	4/2
B × C′	R@5	+0,188	4	0,125	1,000	4/0
B × C′	MRR	+0,080	6	0,438	1,000	4/2
B × C′	nDCG@10	+0,096	7	0,312	1,000	5/2
B × D	P@1	+0,000	2	1,000	1,000	1/1
B × D	P@3	+0,021	3	0,750	1,000	2/1
B × D	R@5	+0,000	0	1,000	1,000	0/0
B × D	MRR	−0,003	4	1,000	1,000	1/3
B × D	nDCG@10	−0,002	5	1,000	1,000	2/3
B × E	P@1	+0,000	2	1,000	1,000	1/1
B × E	P@3	+0,000	2	1,000	1,000	1/1
B × E	R@5	+0,000	0	1,000	1,000	0/0
B × E	MRR	−0,019	3	0,750	1,000	1/2
B × E	nDCG@10	+0,003	5	0,938	1,000	3/2
C × C′	P@1	+0,000	2	1,000	1,000	1/1
C × C′	P@3	+0,062	3	0,250	1,000	3/0
C × C′	R@5	+0,188	4	0,125	1,000	4/0
C × C′	MRR	+0,042	5	0,750	1,000	2/3
C × C′	nDCG@10	+0,046	6	0,625	1,000	2/4
C × D	P@1	−0,125	4	0,625	1,000	1/3
C × D	P@3	+0,042	4	0,625	1,000	3/1
C × D	R@5	+0,000	0	1,000	1,000	0/0
C × D	MRR	−0,042	6	0,688	1,000	3/3
C × D	nDCG@10	−0,052	7	0,469	1,000	3/4
C × E	P@1	−0,125	4	0,625	1,000	1/3
C × E	P@3	+0,021	1	1,000	1,000	1/0
C × E	R@5	+0,000	0	1,000	1,000	0/0
C × E	MRR	−0,057	6	0,562	1,000	2/4
C × E	nDCG@10	−0,047	7	0,469	1,000	2/5
C′ × D	P@1	−0,125	6	0,688	1,000	2/4

Comparação	Medida	Δ (diferença)	*n*	valor-p	valor-p corrigido (Holm)	Vitórias (1º/2º)
C′ × D	P@3	−0,021	5	0,750	1,000	2/3
C′ × D	R@5	−0,188	4	0,125	1,000	0/4
C′ × D	MRR	−0,083	7	0,531	1,000	3/4
C′ × D	nDCG@10	−0,099	8	0,398	1,000	3/5
C′ × E	P@1	−0,125	4	0,625	1,000	1/3
C′ × E	P@3	−0,042	4	0,500	1,000	1/3
C′ × E	R@5	−0,188	4	0,125	1,000	0/4
C′ × E	MRR	−0,099	5	0,375	1,000	2/3
C′ × E	nDCG@10	−0,093	6	0,406	1,000	3/3
D × E	P@1	+0,000	2	1,000	1,000	1/1
D × E	P@3	−0,021	5	0,938	1,000	2/3
D × E	R@5	+0,000	0	1,000	1,000	0/0
D × E	MRR	−0,016	4	0,875	1,000	2/2
D × E	nDCG@10	+0,006	6	0,906	1,000	4/2

Tabela 12 – Comparações entre os pares de braços medidos por seção (unidade: seção).

Comparação	Medida	Δ (diferença)	*n*	valor-p	valor-p corrigido (Holm)	Vitórias (1º/2º)
A × B	P@1	−0,188	3	0,250	1,000	0/3
A × B	P@3	−0,062	3	0,250	1,000	0/3
A × B	R@5	−0,094	2	0,500	1,000	0/2
A × B	MRR	−0,130	6	0,156	1,000	1/5
A × B	nDCG@10	−0,123	6	0,062	0,938	1/5
A × D	P@1	+0,000	0	1,000	1,000	0/0
A × D	P@3	−0,062	3	0,250	1,000	0/3
A × D	R@5	−0,094	2	0,500	1,000	0/2
A × D	MRR	−0,019	5	0,312	1,000	1/4
A × D	nDCG@10	−0,023	4	0,250	1,000	1/3
B × D	P@1	+0,188	3	0,250	1,000	3/0
B × D	P@3	+0,000	0	1,000	1,000	0/0
B × D	R@5	+0,000	0	1,000	1,000	0/0
B × D	MRR	+0,111	5	0,062	0,938	5/0
B × D	nDCG@10	+0,099	5	0,062	0,938	5/0

O que estas tabelas mostram: Nenhuma comparação ficou abaixo de 0,05: o menor valor-p sem correção foi 0,125 por documento e 0,062 por seção, e todos os valores corrigidos ficaram entre 0,938 e 1,000. Com 16 perguntas com resposta, no máximo 8 tiveram resultado diferente em qualquer comparação, o que é pouco para detectar diferenças desse tamanho. C1, portanto, não mostra que a busca por palavras seja igual ou melhor que a busca por significado; mostra só que, neste conjunto, nenhuma diferença foi detectável.

O que concluir

- Escolhendo entre textos inteiros, todos os braços ficaram próximos, e nenhuma diferença pode ser separada do acaso com só 16 perguntas com resposta.
- Escolhendo entre seções, tarefa mais difícil e mais parecida com o uso real, o BM25 pôs o texto certo em 1º lugar mais vezes que a contagem de palavras (0,750 contra 0,562); por isso o sistema passou a usar o BM25.
- A busca por palavras depende de a pergunta usar as palavras do texto: acerta todas as literais e cai nas paráfrases. A busca por significado depende menos disso, mas acerta menos as literais.
- Nenhuma forma de busca reconhece sozinha uma pergunta sem resposta; no sistema, isso fica a cargo do modelo de linguagem que redige a resposta.
- A busca por palavras e a busca exata por significado dão sempre a mesma lista; o índice aproximado só foi instável numa configuração fora da recomendada. As 155 unidades guardadas têm a origem completa no banco.