Anexo A7 – Resultados do teste de busca

ThingIndex – Trabalho de Conclusão de Curso – Sistemas de Informação – IFPR Campus Palmas

1. Como o teste foi feito

Para comparar formas de busca sem depender de documentos externos, o autor escreveu cinco textos curtos, de temas jurídico, contratual e normativo, e 18 perguntas sobre eles. Dezesseis perguntas têm resposta em um dos textos; duas não têm resposta em nenhum. Como os textos foram escritos pelo autor, sabe-se de antemão qual é o texto certo de cada pergunta, o que permite contar quantas vezes cada método o colocou no topo da lista de resultados. Os seis métodos comparados estão no Quadro 1, e os resultados correspondem às Seções 8.1 a 8.4 do artigo.

Quadro 1 – Métodos de busca comparados.

Método	Como funciona
Contagem de palavras (versão antiga)	Conta quantas palavras da pergunta aparecem em cada texto. Foi a busca da primeira versão do ThingIndex.
BM25 (busca por palavras, usada no sistema)	Também compara palavras, mas pesa mais as raras, que dizem mais sobre o assunto, e menos as que se repetem. É a busca usada hoje pelo sistema.
Busca por significado, exata	Um modelo de linguagem converte a pergunta e cada texto em vetores numéricos, de modo que textos de sentido parecido fiquem próximos, mesmo sem palavras em comum. A pergunta é comparada com todos os textos.
Busca por significado, aproximada	Os mesmos vetores, mas guardados num índice que os divide em grupos e consulta só parte deles. É mais rápida em acervos grandes, ao custo de às vezes deixar o texto certo de fora.
Contagem + BM25 combinados	Combina as listas da contagem e do BM25, somando pontos pela posição de cada texto em cada lista.
BM25 + significado combinados	Mesma combinação, entre o BM25 e a busca por significado exata.

Cada método devolve uma lista ordenada de textos. A medida usada no corpo deste anexo é a mais intuitiva: a porcentagem de perguntas em que o primeiro resultado da lista era o texto certo. As demais medidas estão na Seção 8.

2. Qual método acertou o primeiro resultado

O teste foi feito em dois níveis. No primeiro, cada método escolhia entre os cinco textos inteiros, situação em que até um sorteio acertaria cerca de uma vez em cinco. No segundo, os textos foram divididos em 19 seções, e o método precisava apontar a seção certa. Esse segundo nível é mais difícil e mais próximo do funcionamento real do sistema, que devolve trechos, e não documentos inteiros. A busca por significado foi medida só no primeiro nível, porque os vetores foram calculados para os textos inteiros.

Tabela 1 – Perguntas em que o primeiro resultado era o texto certo.

Método	Escolhendo entre 5 textos	Escolhendo entre 19 seções
Contagem de palavras (versão antiga)	75,0%	56,2%
BM25 (busca por palavras, usada no sistema)	81,2%	75,0%
Busca por significado, exata	68,8%	não medido
Busca por significado, aproximada	68,8%	não medido
Contagem + BM25 combinados	81,2%	56,2%
BM25 + significado combinados	81,2%	não medido

O BM25 acertou 81,2% das perguntas entre os textos inteiros, empatado com as duas combinações, e 75,0% entre as seções, contra 56,2% da contagem de palavras. Foi essa diferença no nível das seções que levou o sistema a trocar a contagem pelo BM25. Entre os textos inteiros, as diferenças são pequenas: cada pergunta vale pouco mais de seis pontos percentuais, e a distância entre o BM25 e a contagem é de uma só pergunta.

3. Efeito da forma de escrever a pergunta

As 16 perguntas com resposta foram escritas de três formas: cinco repetem as palavras do texto, sete pedem a mesma informação com outras palavras, como faria quem não leu o documento, e quatro têm erros de digitação e falta de acentos. As Tabelas 2 e 3 separam o acerto do primeiro resultado por forma de pergunta.

Tabela 2 – Primeiro resultado certo, por forma da pergunta, escolhendo entre 5 textos.

Método	Com as palavras do texto	Com outras palavras	Com erros de digitação
Contagem de palavras (versão antiga)	100,0%	57,1%	75,0%
BM25 (busca por palavras, usada no sistema)	100,0%	71,4%	75,0%
Busca por significado, exata	60,0%	57,1%	100,0%
Busca por significado, aproximada	60,0%	71,4%	75,0%
Contagem + BM25 combinados	100,0%	57,1%	100,0%
BM25 + significado combinados	80,0%	71,4%	100,0%

Tabela 3 – Primeiro resultado certo, por forma da pergunta, escolhendo entre 19 seções.

Método	Com as palavras do texto	Com outras palavras	Com erros de digitação
Contagem de palavras (versão antiga)	100,0%	14,3%	75,0%
BM25 (busca por palavras, usada no sistema)	100,0%	42,9%	100,0%
Contagem + BM25 combinados	100,0%	14,3%	75,0%

As buscas por palavras acertaram todas as perguntas que repetem o texto e caíram quando a pergunta usou outras palavras: para 57,1% na contagem e 71,4% no BM25. Entre as seções a queda é maior, e a contagem acertou só 14,3% dessas perguntas. A busca por significado se comporta de outro modo: quase não perde com outras palavras (60,0% contra 57,1%), mas acerta menos as perguntas que repetem o texto. Os dois tipos de busca erram em perguntas diferentes, o que explica por que a combinação do BM25 com a busca por significado ficou entre as melhores.

4. As diferenças são confiáveis?

Com apenas 16 perguntas, uma pergunta a mais ou a menos muda bastante a porcentagem. Por isso, cada resultado foi acompanhado de um **intervalo de confiança**, a faixa em que o valor verdadeiro provavelmente está. O BM25, por exemplo, acertou 81,2%, mas o valor verdadeiro pode estar entre 62,5% e 100,0%; para a contagem de palavras (75,0%), a faixa vai de 50,0% a 93,8%. Como as faixas se sobrepõem, não é possível afirmar que um método seja melhor que o outro.

Os métodos também foram comparados dois a dois por um teste estatístico, que estima a chance de uma diferença ter surgido por acaso. Em geral, só se considera a diferença real quando essa chance fica abaixo de 5%. Foram 75 comparações entre os textos inteiros e 15 entre as seções. A menor chance de acaso foi de 12,5% no primeiro caso e de 6,2% no segundo. Como são muitas comparações ao mesmo tempo, o teste é ajustado para não apontar

diferenças por sorte, e com o ajuste nenhuma chance ficou abaixo de 93,8%. Em nenhuma comparação os dois métodos divergiram em mais de 8 das 16 perguntas.

A conclusão é limitada pelo tamanho do teste: ele não mostra que a busca por palavras seja melhor nem pior que a busca por significado, apenas que, com 16 perguntas, nenhuma diferença entre os métodos pôde ser confirmada.

5. Perguntas sem resposta

Nas duas perguntas que não têm resposta em nenhum texto, o comportamento desejado seria não devolver nada. Todos os métodos, porém, devolveram resultados nas duas. Na busca por palavras, basta uma palavra em comum para que um texto receba alguma nota; a busca aproximada devolveu menos textos (2,5 em média, contra 5,0 dos demais), por consultar só parte dos grupos, mas também não deixou a lista vazia.

Testou-se ainda uma nota mínima para descartar resultados fracos, escolhida da forma mais favorável possível. Mesmo assim, a contagem e o BM25 continuaram devolvendo resultados em uma das duas perguntas, porque as notas de textos certos e errados se sobrepõem. No sistema completo, a ausência de resposta é reconhecida em outra etapa: o modelo de linguagem, instruído a responder apenas com base nas fontes, declarou que a informação não consta em todas as 14 perguntas sem resposta dos demais acervos, nas três repetições (Seção 8.2 do artigo).

6. Estabilidade dos resultados

Um dos requisitos do ThingIndex é que a mesma pergunta traga sempre as mesmas fontes, na mesma ordem. Para verificar isso, cada método respondeu às 18 perguntas 30 vezes, e as listas foram comparadas (Tabela 4).

Tabela 4 – A mesma pergunta trouxe sempre a mesma lista?

Método	**Resultado nas 30 repetições**
Contagem de palavras (versão antiga)	Sim
BM25 (busca por palavras, usada no sistema)	Sim
Contagem + BM25 combinados	Sim
Busca por significado, exata	Sim
Busca por significado, aproximada	Não. Mudando o sorteio que forma os grupos ou a ordem de entrada dos textos, nenhuma pergunta (0%) manteve sempre a mesma lista, e houve até 4 listas diferentes para a mesma pergunta. Em média, perdeu 48,4% dos resultados da busca exata.
BM25 + significado combinados	Não medido separadamente

A busca aproximada usada no teste tinha uma configuração desfavorável: muitos grupos e apenas um consultado por busca. Para saber se a instabilidade vinha da configuração ou do tipo de índice, o teste foi repetido no próprio pgvector, a extensão do PostgreSQL que guarda vetores, com 1.000, 5.000 e 20.000 textos artificiais e 20 perguntas. Foram medidos os dois índices aproximados do pgvector: o IVFFlat, que divide os vetores em grupos, e o HNSW, que liga cada vetor aos vizinhos mais parecidos. A Tabela 5 mostra quanto dos dez primeiros resultados coincidiu com a busca exata e em quantas das 20 perguntas a lista mudou ao reconstruir o índice cinco vezes e ao inserir os dados em cinco ordens diferentes.

Tabela 5 – Busca aproximada no pgvector.

Índice	Textos	Igual à busca exata	Mudou ao reconstruir	Mudou com outra ordem
IVFFlat, configuração do teste	1.000	47,7%	20 de 20	20 de 20
IVFFlat, configuração recomendada	1.000	100,0%	0 de 20	0 de 20
HNSW, configuração padrão	1.000	100,0%	0 de 20	0 de 20
IVFFlat, configuração do teste	5.000	36,5%	20 de 20	20 de 20
IVFFlat, configuração recomendada	5.000	100,0%	0 de 20	0 de 20
HNSW, configuração padrão	5.000	99,0%	2 de 20	4 de 20
IVFFlat, configuração do teste	20.000	25,5%	20 de 20	20 de 20
IVFFlat, configuração recomendada	20.000	100,0%	0 de 20	0 de 20
HNSW, configuração padrão	20.000	91,0%	6 de 20	17 de 20

Com a configuração recomendada, o IVFFlat devolveu sempre o mesmo que a busca exata. O HNSW foi exato com 1.000 textos, mas com 20.000 coincidiu em 91,0% e mudou em 6 e em 17 das 20 perguntas. A instabilidade, portanto, depende da configuração e do tamanho do acervo, e não é exclusiva da busca por significado: nas coleções que o ThingIndex atende, um índice bem configurado também seria estável.

7. Origem dos trechos no banco

Ao indexar um documento, o sistema guarda no banco partes de vários tipos: páginas, parágrafos, trechos (as partes citadas como fonte), itens do sumário e dados gerais do documento, como o número de parágrafos. Cada parte deve registrar de onde veio: o documento, a página, a posição e o conteúdo. Nos cinco textos do teste são 155 partes, e a porcentagem com a origem completa evoluiu assim:

- **32,9%** (51 de 155) na primeira medição; todas as partes incompletas estavam sem página;
- **45,2%** (70 de 155) depois de criar a coluna de página na tabela de trechos, que não existia;
- **100,0%** (155 de 155) depois de ajustar a regra da medida: os 85 dados gerais não pertencem a nenhuma página e passaram a declarar que vêm do documento inteiro.

Parte da melhora veio de corrigir o sistema, e parte de ajustar a medida (Seção 8.4 do artigo). Como os textos do teste não têm páginas, o resultado mostra que o sistema registra a origem de cada parte, e não que a página registrada esteja certa; isso é verificado nos PDFs reais, nas demais seções do artigo.

8. Tabelas completas

Esta seção reúne, para conferência, todas as tabelas do teste, com os números em porcentagem ou em nota de 0 a 100. O Quadro 2 explica cada medida; a última coluna traz o nome usado na literatura de recuperação de informação.

Quadro 2 – Medidas usadas nas tabelas completas.

Medida	O que mede	Nome técnico
1º lugar	Porcentagem de perguntas em que o primeiro resultado era o texto certo.	P@1
3 primeiros	Porcentagem dos três primeiros resultados que eram certos. Como quase toda pergunta tem um único texto certo, nem uma busca perfeita chega perto de 100%; o máximo possível aparece na última linha das tabelas.	P@3
5 primeiros	Porcentagem de perguntas em que o texto certo apareceu entre os cinco primeiros resultados.	R@5
Posição	Nota de 0 a 100 pela posição do texto certo: 100 em primeiro lugar, 50 em segundo, 33,3 em terceiro, e assim por diante; a nota final é a média.	MRR
Ordem	Nota de 0 a 100 parecida com a anterior, considerando os dez primeiros resultados.	nDCG@10
(de X a Y)	Intervalo de confiança de 95%, calculado sorteando as perguntas 10 mil vezes.	bootstrap
Diferença	Distância entre duas porcentagens, em pontos percentuais (81,2% − 75,0% = 6,2 pontos). Positiva quando o primeiro método foi melhor.	Δ
Chance de acaso	Probabilidade de a diferença ter surgido por sorte; a coluna seguinte traz o mesmo valor ajustado para as muitas comparações.	valor-p; correção de Holm
Devolveu algo	Porcentagem das perguntas sem resposta em que o método devolveu resultados.	falso positivo
Nota mínima	Nota da própria busca abaixo da qual o resultado seria descartado; não é porcentagem.	limiar
Separação	Nota de 0 a 100 de quanto a nota mínima separa textos certos de errados (100 separa todos; 0 equivale ao acaso).	índice de Youden
Sobreposição	Porcentagem dos textos errados que tiveram nota maior que a do texto certo de nota mais baixa.	

Tabela D1 – Todas as medidas, escolhendo entre 5 textos. Abaixo de cada número, o intervalo de confiança.

Método	1º lugar (%)	3 primeiros (%)	5 primeiros (%)	Posição (nota 0–100)	Ordem (nota 0–100)
Contagem de palavras (versão antiga)	75,0 (de 50,0 a 93,8)	31,2 (de 25,0 a 37,5)	100,0 (de 100,0 a 100,0)	83,0 (de 66,9 a 95,8)	86,9 (de 74,8 a 96,8)
BM25 (busca por palavras, usada no sistema)	81,2 (de 62,5 a 100,0)	33,3 (de 25,0 a 41,7)	100,0 (de 100,0 a 100,0)	86,1 (de 71,5 a 100,0)	89,4 (de 78,3 a 99,8)
Busca por significado, exata	68,8 (de 43,8 a 87,5)	35,4 (de 33,3 a 39,6)	100,0 (de 100,0 a 100,0)	82,3 (de 68,7 a 93,8)	84,4 (de 74,2 a 94,4)
Busca por significado, aproximada	68,8 (de 43,8 a 87,5)	29,2 (de 22,9 a 33,3)	81,2 (de 62,5 a 96,9)	78,1 (de 59,4 a 93,8)	79,7 (de 61,5 a 94,5)
Contagem + BM25 combinados	81,2 (de 62,5 a 100,0)	31,2 (de 25,0 a 37,5)	100,0 (de 100,0 a 100,0)	86,5 (de 71,9 a 100,0)	89,6 (de 78,7 a 99,7)
BM25 + significado combinados	81,2 (de 62,5 a 100,0)	33,3 (de 27,1 a 39,6)	100,0 (de 100,0 a 100,0)	88,0 (de 74,5 a 100,0)	89,0 (de 78,8 a 97,5)
Máximo possível	100,0	37,5	100,0	—	—

Tabela D2 – Todas as medidas, escolhendo entre 19 seções (só os métodos medidos nesse nível).

Método	1º lugar (%)	3 primeiros (%)	5 primeiros (%)	Posição (nota 0–100)	Ordem (nota 0–100)
Contagem de palavras (versão antiga)	56,2 (de 31,2 a 81,2)	29,2 (de 18,7 a 39,6)	71,9 (de 53,1 a 90,6)	68,9 (de 49,9 a 86,4)	70,6 (de 52,1 a 87,3)
BM25 (busca por palavras, usada no sistema)	75,0 (de 50,0 a 93,8)	35,4 (de 27,1 a 43,8)	81,2 (de 62,5 a 96,9)	81,8 (de 64,6 a 95,8)	82,9 (de 66,5 a 95,8)
Contagem + BM25 combinados	56,2 (de 31,2 a 81,2)	35,4 (de 27,1 a 43,8)	81,2 (de 62,5 a 96,9)	70,7 (de 53,0 a 86,9)	72,9 (de 55,0 a 88,3)
Máximo possível	100,0	45,8	100,0	—	—

Tabela D3 – Primeiro resultado certo, por forma da pergunta, escolhendo entre 5 textos.

Método	Palavras do texto (%)	Outras palavras (%)	Erros de digitação (%)	Queda com outras palavras (pontos)
Contagem de palavras (versão antiga)	100,0	57,1	75,0	+42,9
BM25 (busca por palavras, usada no sistema)	100,0	71,4	75,0	+28,6
Busca por significado, exata	60,0	57,1	100,0	+2,9
Busca por significado, aproximada	60,0	71,4	75,0	−11,4
Contagem + BM25 combinados	100,0	57,1	100,0	+42,9
BM25 + significado combinados	80,0	71,4	100,0	+8,6

Tabela D4 – Primeiro resultado certo, por forma da pergunta, escolhendo entre 19 seções.

Método	Palavras do texto (%)	Outras palavras (%)	Erros de digitação (%)	Queda com outras palavras (pontos)
Contagem de palavras (versão antiga)	100,0	14,3	75,0	+85,7
BM25 (busca por palavras, usada no sistema)	100,0	42,9	100,0	+57,1
Contagem + BM25 combinados	100,0	14,3	75,0	+85,7

Tabela D5 – As 2 perguntas sem resposta, escolhendo entre 5 textos.

Método	Devolveu algo (%)	Resultados devolvidos (média)
Contagem de palavras (versão antiga)	100,0	5,0
BM25 (busca por palavras, usada no sistema)	100,0	5,0
Busca por significado, exata	100,0	5,0
Busca por significado, aproximada	100,0	2,5
Contagem + BM25 combinados	100,0	5,0
BM25 + significado combinados	100,0	5,0

Tabela D6 – As 2 perguntas sem resposta, escolhendo entre 19 seções.

Método	Devolveu algo (%)	Resultados devolvidos (média)
Contagem de palavras (versão antiga)	100,0	19,0
BM25 (busca por palavras, usada no sistema)	100,0	18,0
Contagem + BM25 combinados	100,0	19,0

Tabela D7 – Tentativa de usar uma nota mínima para descartar resultados (escolhendo entre 5 textos).

Método	Sobreposição (%)	Nota mínima	Separação (0–100)	Devolveu algo sem nota mínima (%)	Devolveu algo com nota mínima (%)
Contagem de palavras (versão antiga)	78,2	4,000	28,8	100,0	50,0
BM25 (busca por palavras, usada no sistema)	98,0	2,127	67,3	100,0	50,0

Tabela D8 – A busca por significado deu sempre a mesma lista? Uma pergunta é estável quando a lista completa, com as notas, sai idêntica em todas as repetições.

O que foi variado	Perguntas estáveis	Listas diferentes	Resultados perdidos frente à busca exata
Busca por significado, exata: repetida 30 vezes	100%	1	–
Busca por significado, aproximada: 30 sorteios diferentes dos grupos	0%	4	48,4%
Busca por significado, aproximada: textos inseridos em 30 ordens	0%	4	–
Busca por significado, aproximada: olhando de 1 grupo até todos	0%	2	–

Tabela D9 – Busca aproximada no pgvector 0.8.6, com textos artificiais (768 números cada) e 20 perguntas. As duas últimas colunas contam as perguntas cujos 10 primeiros resultados mudaram (5 reconstruções; 5 ordens).

Tipo de busca	Vetores (*N*)	Encontrou o mesmo que a busca exata nos 10 primeiros	Mudou ao reconstruir	Mudou ao trocar a ordem
IVFFlat como no teste: muitos grupos, só 1 consultado	1.000	47,7%	20/20	20/20
IVFFlat, configuração recomendada	1.000	100,0%	0/20	0/20
HNSW, configuração padrão	1.000	100,0%	0/20	0/20
IVFFlat como no teste: muitos grupos, só 1 consultado	5.000	36,5%	20/20	20/20
IVFFlat, configuração recomendada	5.000	100,0%	0/20	0/20
HNSW, configuração padrão	5.000	99,0%	2/20	4/20
IVFFlat como no teste: muitos grupos, só 1 consultado	20.000	25,5%	20/20	20/20
IVFFlat, configuração recomendada	20.000	100,0%	0/20	0/20
HNSW, configuração padrão	20.000	91,0%	6/20	17/20

Tabela D10 – Pedaços guardados no banco com a origem completa (documento, página, posição e conteúdo), na versão atual. Os dados gerais do documento não exigem página.

Tipo de pedaço	Pedaços	Com origem completa	Origem completa (%)
Trecho (o pedaço citado como fonte)	19	19	100,0
Dado geral do documento	85	85	100,0
Item do sumário	26	26	100,0
Página	5	5	100,0
Parágrafo	20	20	100,0
Total	**155**	**155**	**100,0**

Tabela D11 – As 75 comparações dois a dois, escolhendo entre 5 textos. Em cada bloco, as colunas são: a medida; a diferença em pontos (primeiro método menos o segundo); em quantas das 16 perguntas os dois divergiram e, entre parênteses, quantas cada um venceu; a chance de acaso (%); e a mesma chance ajustada para muitas comparações (%).

Contagem de palavras (versão antiga) × BM25 (busca por palavras, usada no sistema)				
1º lugar	−6,2	1 (0 e 1)	100,0	100,0
3 primeiros	−2,1	3 (1 e 2)	75,0	100,0
5 primeiros	+0,0	0 (0 e 0)	100,0	100,0
Posição	−3,1	4 (3 e 1)	100,0	100,0
Ordem	−2,5	5 (3 e 2)	93,8	100,0

Contagem de palavras (versão antiga) × Busca por significado, exata				
1º lugar	+6,2	5 (3 e 2)	100,0	100,0
3 primeiros	−4,2	2 (0 e 2)	50,0	100,0
5 primeiros	+0,0	0 (0 e 0)	100,0	100,0
Posição	+0,7	7 (3 e 4)	98,4	100,0
Ordem	+2,5	8 (4 e 4)	72,7	100,0

Contagem de palavras (versão antiga) × Busca por significado, aproximada				
1º lugar	+6,2	5 (3 e 2)	100,0	100,0
3 primeiros	+2,1	5 (3 e 2)	75,0	100,0
5 primeiros	+18,8	4 (4 e 0)	12,5	100,0
Posição	+4,9	7 (4 e 3)	65,6	100,0
Ordem	+7,1	8 (5 e 3)	49,2	100,0

Contagem de palavras (versão antiga) × Contagem + BM25 combinados				
1º lugar	−6,2	1 (0 e 1)	100,0	100,0
3 primeiros	+0,0	2 (1 e 1)	100,0	100,0
5 primeiros	+0,0	0 (0 e 0)	100,0	100,0
Posição	−3,4	2 (0 e 2)	50,0	100,0
Ordem	−2,7	4 (1 e 3)	25,0	100,0

Contagem de palavras (versão antiga) × BM25 + significado combinados				
1º lugar	−6,2	3 (1 e 2)	100,0	100,0
3 primeiros	−2,1	3 (1 e 2)	100,0	100,0
5 primeiros	+0,0	0 (0 e 0)	100,0	100,0
Posição	−5,0	5 (2 e 3)	62,5	100,0
Ordem	−2,2	7 (3 e 4)	71,9	100,0

BM25 (busca por palavras, usada no sistema) × Busca por significado, exata				
1º lugar	+12,5	6 (4 e 2)	68,8	100,0
3 primeiros	−2,1	3 (1 e 2)	100,0	100,0
5 primeiros	+0,0	0 (0 e 0)	100,0	100,0
Posição	+3,9	7 (4 e 3)	73,4	100,0
Ordem	+5,0	8 (5 e 3)	53,1	100,0

BM25 (busca por palavras, usada no sistema) × Busca por significado, aproximada				
1º lugar	+12,5	4 (3 e 1)	62,5	100,0
3 primeiros	+4,2	6 (4 e 2)	40,6	100,0
5 primeiros	+18,8	4 (4 e 0)	12,5	100,0
Posição	+8,0	6 (4 e 2)	43,8	100,0
Ordem	+9,6	7 (5 e 2)	31,2	100,0

BM25 (busca por palavras, usada no sistema) × Contagem + BM25 combinados				
1º lugar	+0,0	2 (1 e 1)	100,0	100,0
3 primeiros	+2,1	3 (2 e 1)	75,0	100,0
5 primeiros	+0,0	0 (0 e 0)	100,0	100,0
Posição	−0,3	4 (1 e 3)	100,0	100,0
Ordem	−0,2	5 (2 e 3)	100,0	100,0

BM25 (busca por palavras, usada no sistema) × BM25 + significado combinados				
1º lugar	+0,0	2 (1 e 1)	100,0	100,0
3 primeiros	+0,0	2 (1 e 1)	100,0	100,0
5 primeiros	+0,0	0 (0 e 0)	100,0	100,0
Posição	−1,9	3 (1 e 2)	75,0	100,0
Ordem	+0,3	5 (3 e 2)	93,8	100,0

Busca por significado, exata × Busca por significado, aproximada				
1º lugar	+0,0	2 (1 e 1)	100,0	100,0
3 primeiros	+6,2	3 (3 e 0)	25,0	100,0
5 primeiros	+18,8	4 (4 e 0)	12,5	100,0
Posição	+4,2	5 (2 e 3)	75,0	100,0
Ordem	+4,6	6 (2 e 4)	62,5	100,0

Busca por significado, exata × Contagem + BM25 combinados				
1º lugar	−12,5	4 (1 e 3)	62,5	100,0
3 primeiros	+4,2	4 (3 e 1)	62,5	100,0
5 primeiros	+0,0	0 (0 e 0)	100,0	100,0
Posição	−4,2	6 (3 e 3)	68,8	100,0
Ordem	−5,2	7 (3 e 4)	46,9	100,0

Busca por significado, exata × BM25 + significado combinados				
1º lugar	−12,5	4 (1 e 3)	62,5	100,0
3 primeiros	+2,1	1 (1 e 0)	100,0	100,0
5 primeiros	+0,0	0 (0 e 0)	100,0	100,0
Posição	−5,7	6 (2 e 4)	56,2	100,0
Ordem	−4,7	7 (2 e 5)	46,9	100,0

Busca por significado, aproximada × Contagem + BM25 combinados				
1º lugar	−12,5	6 (2 e 4)	68,8	100,0
3 primeiros	−2,1	5 (2 e 3)	75,0	100,0
5 primeiros	−18,8	4 (0 e 4)	12,5	100,0
Posição	−8,3	7 (3 e 4)	53,1	100,0
Ordem	−9,9	8 (3 e 5)	39,8	100,0

Busca por significado, aproximada × BM25 + significado combinados				
1º lugar	−12,5	4 (1 e 3)	62,5	100,0
3 primeiros	−4,2	4 (1 e 3)	50,0	100,0
5 primeiros	−18,8	4 (0 e 4)	12,5	100,0
Posição	−9,9	5 (2 e 3)	37,5	100,0
Ordem	−9,3	6 (3 e 3)	40,6	100,0

Contagem + BM25 combinados × BM25 + significado combinados				
1º lugar	+0,0	2 (1 e 1)	100,0	100,0
3 primeiros	−2,1	5 (2 e 3)	93,8	100,0
5 primeiros	+0,0	0 (0 e 0)	100,0	100,0
Posição	−1,6	4 (2 e 2)	87,5	100,0
Ordem	+0,6	6 (4 e 2)	90,6	100,0

Tabela D12 – As 15 comparações dois a dois, escolhendo entre 19 seções, no mesmo formato.

Contagem de palavras (versão antiga) × BM25 (busca por palavras, usada no sistema)				
1º lugar	−18,8	3 (0 e 3)	25,0	100,0
3 primeiros	−6,2	3 (0 e 3)	25,0	100,0
5 primeiros	−9,4	2 (0 e 2)	50,0	100,0
Posição	−13,0	6 (1 e 5)	15,6	100,0
Ordem	−12,3	6 (1 e 5)	6,2	93,8

BM25 (busca por palavras, usada no sistema) × Contagem + BM25 combinados				
1º lugar	+18,8	3 (3 e 0)	25,0	100,0
3 primeiros	+0,0	0 (0 e 0)	100,0	100,0
5 primeiros	+0,0	0 (0 e 0)	100,0	100,0
Posição	+11,1	5 (5 e 0)	6,2	93,8
Ordem	+9,9	5 (5 e 0)	6,2	93,8

Contagem de palavras (versão antiga) × Contagem + BM25 combinados				
1º lugar	+0,0	0 (0 e 0)	100,0	100,0
3 primeiros	−6,2	3 (0 e 3)	25,0	100,0
5 primeiros	−9,4	2 (0 e 2)	50,0	100,0
Posição	−1,9	5 (1 e 4)	31,2	100,0
Ordem	−2,3	4 (1 e 3)	25,0	100,0