Anexo A7 – Resultados do teste de busca

ThingIndex – Trabalho de Conclusão de Curso – Sistemas de Informação – IFPR Campus Palmas

Por que este teste foi feito

A pergunta do TCC é se dá para montar o sistema sem banco de vetores, só com o banco relacional e uma busca por palavras. Antes de construir o resto do sistema em cima dessa escolha, era preciso saber duas coisas: se a busca por palavras encontra o trecho certo pelo menos tão bem quanto a busca por significado, que é a opção usual, e se ela devolve sempre o mesmo resultado, já que o sistema promete fontes que possam ser conferidas de novo.

O teste é pequeno e controlado, separado dos acervos de PDFs públicos usados no restante do artigo. São cinco textos curtos e fictícios (um acórdão, um edital de pregão, um contrato de TI, uma política de privacidade e um manual de integração) e 18 perguntas sobre eles; 16 têm resposta e 2 não. Como os textos foram criados para o teste, sabe-se qual é o texto certo de cada pergunta. No texto deste anexo, a medida é uma só: em quantas perguntas o primeiro resultado da busca era o texto certo.

1. A busca por palavras acha o texto certo?

Se a busca por palavras errasse muito mais que a busca por significado, a proposta do TCC não se sustentaria. Foram comparados seis métodos: a contagem de palavras da primeira versão do sistema, o BM25 (busca por palavras que pesa mais as palavras raras, usada hoje), a busca por significado com vetores, em versão exata e aproximada, e duas combinações. Cada um escolheu o texto certo entre os cinco textos inteiros e, num teste mais difícil e mais parecido com o sistema real, a seção certa entre 19 seções.

Tabela 1 – Perguntas em que o primeiro resultado era o texto certo.

Método	Entre 5 textos	Entre 19 seções
Contagem de palavras (versão antiga)	75,0%	56,2%
BM25 (busca por palavras, usada no sistema)	81,2%	75,0%
Busca por significado, exata	68,8%	não medido
Busca por significado, aproximada	68,8%	não medido
Contagem + BM25 combinados	81,2%	56,2%
BM25 + significado combinados	81,2%	não medido

O BM25 acertou 81,2% entre os textos inteiros, e a busca por significado, 68,8%. São duas perguntas de diferença em 16, pouco para afirmar que um é melhor (ver a seção 3): neste teste, as duas buscas ficaram próximas. Entre as seções, o BM25 acertou 75,0% e a contagem de palavras, 56,2%. Como o sistema devolve trechos, e não documentos inteiros, foi esse resultado que levou à troca da contagem pelo BM25, usado em todos os experimentos seguintes.

2. Onde cada busca falha?

Quem consulta uma norma nem sempre conhece os termos dela. Por isso as perguntas foram escritas de três jeitos: repetindo as palavras do texto, com outras palavras (como faria quem não leu o documento) e com erros de digitação.

Tabela 2 – Primeiro resultado certo, por jeito de escrever a pergunta (entre 5 textos).

Método	Com as palavras do texto	Com outras palavras
Contagem de palavras (versão antiga)	100,0%	57,1%
BM25 (busca por palavras, usada no sistema)	100,0%	71,4%
Busca por significado, exata	60,0%	57,1%

As buscas por palavras acertaram todas as perguntas que repetem o texto e caíram bastante quando a pergunta usou outras palavras. Entre as seções a queda foi maior: a contagem acertou só 14,3% dessas perguntas. A busca por significado quase não muda com as palavras, mas erra mais justamente quando a pergunta repete o texto. Esse ponto fraco da busca por palavras levou ao teste de expansão da pergunta, em que o modelo de linguagem sugere os termos técnicos antes da busca (Seção 8.9 do artigo).

3. As diferenças são confiáveis?

Com 16 perguntas, cada pergunta vale pouco mais de seis pontos percentuais, e uma diferença pequena pode ser sorte. Cada dupla de métodos passou por um teste estatístico que calcula com que frequência uma diferença desse tamanho apareceria se, na verdade, os dois métodos fossem iguais (o valor-p); em geral, só se aceita a diferença como real quando esse valor fica abaixo de 5%. Entre os textos inteiros, o menor valor-p foi 0,125, em 75 comparações, e, entre as seções, 0,062, em 15 comparações. Nenhuma diferença pôde ser confirmada.

O teste, então, não diz que a busca por palavras é melhor nem pior que a busca por significado. Diz que, nessa escala, as duas ficaram próximas. Foi por isso que o artigo tratou a escolha da busca por palavras como uma questão de simplicidade de operação.

4. A mesma pergunta traz sempre o mesmo resultado?

Uma fonte conferida hoje precisa continuar aparecendo amanhã. Cada método respondeu às perguntas 30 vezes, e as listas foram comparadas. A busca por palavras, as combinações e a busca por significado exata deram sempre a mesma lista. A versão aproximada, que usa um índice para acelerar a busca em acervos grandes, mudou o resultado de todas as perguntas e deixou de fora, em média, 48,4% do que a busca exata encontrava.

O teste foi repetido no pgvector, a extensão do PostgreSQL para vetores, com até 20.000 textos artificiais (Tabela 5, no fim do anexo). O índice IVFFlat, com a configuração recomendada pela documentação, deu sempre o mesmo resultado da busca exata nos três tamanhos. O HNSW, com os parâmetros padrão, foi estável com 1.000 textos e passou a mudar algumas consultas a partir de 5.000. A estabilidade depende, portanto, do índice e da configuração escolhidos.

5. E quando a pergunta não tem resposta?

Nas duas perguntas sem resposta, todos os métodos devolveram algum texto. Na busca por palavras, basta uma palavra em comum para um texto receber nota, e nem uma nota mínima de corte resolveu. No sistema completo, quem reconhece a falta de resposta é o modelo de linguagem, que recebe só as fontes encontradas e, nos outros acervos, declarou que a informação não consta em todas as perguntas sem resposta (Seção 8.2 do artigo).

6. A origem de cada trecho está gravada?

É a promessa central do sistema: toda fonte aponta documento e página. Das 155 partes que o sistema guardou no banco para os cinco textos, só 32,9% tinham a origem completa na primeira medição. O motivo era um defeito real: a tabela de trechos não tinha coluna de página. A coluna foi criada (45,2%), e os dados gerais do documento, como o número de parágrafos, que não pertencem a nenhuma página, passaram a declarar que vêm do documento inteiro (100%).

O que o teste decidiu

O teste não encontrou diferença confirmável entre a busca por palavras e a busca por significado e levou à troca da contagem de palavras pelo BM25. Também apontou o ponto fraco da busca por palavras, a pergunta escrita com outras palavras, que motivou a expansão da pergunta. E encontrou a falta da página na tabela de trechos, corrigida antes dos experimentos com PDFs reais.

Como os números do artigo foram testados

Esta parte junta o detalhe estatístico que o artigo resume em uma frase, para o teste de busca e para os demais experimentos.

Duas condições nas mesmas perguntas. Para saber se uma diferença pode ser acaso, usou-se o teste de McNemar exato. Ele olha só as perguntas em que as duas condições discordam (uma acerta e a outra erra) e calcula a chance de as discordâncias penderem tanto para um lado se as duas condições fossem iguais. Cada pergunta entra uma vez: conta como certa só quando acertou nas três repetições. Na bateria, a redação da pergunta deu 15 pares a 0 a favor da versão com as palavras do documento (valor-p menor que 0,001), e a expansão da pergunta ganhou 15 perguntas e não perdeu nenhuma (valor-p menor que 0,001). Os valores com o gabarito original estão no Anexo A8.

Intervalos de confiança. O intervalo de 95% é a faixa em que o acerto provavelmente ficaria com outras perguntas do mesmo tipo. Foi calculado sorteando 10.000 vezes, com reposição, novos conjuntos das mesmas perguntas (*bootstrap*), com as três respostas de cada pergunta sorteadas juntas, porque elas não são independentes. Na bateria, com a pergunta original, o acerto total ficou entre 57,3% e 77,9%; por acervo, segurança do trabalho, de 37,7% a 78,3%; produto e consumidor, de 65,2% a 95,7%; licitações, de 44,0% a 84,0%. As faixas dos três acervos se sobrepõem, e por isso o artigo não diz que um foi mais fácil que outro. Com expansão, o total ficou entre 80,3% e 95,8%.

Teste de busca (C1). Aqui nem todas as medidas são certo ou errado, então usou-se o teste de aleatorização pareado: ele troca ao acaso, consulta a consulta, os resultados dos dois métodos e verifica com que frequência surge uma diferença tão grande quanto a real. Numa medida de certo ou errado, como o primeiro resultado, ele dá o mesmo valor-p que o McNemar exato. Foram 90 comparações (75 entre os textos inteiros e 15 entre as seções). Quanto mais comparações, maior a chance de alguma parecer real só por sorte; por isso aplicou-se, em cada grupo, a correção de Holm, que exige valores-p menores quando há mais comparações. Já antes da correção nenhuma diferença ficou abaixo de 5% (menor valor-p de 0,125 entre os textos e 0,062 entre as seções; seção 3); depois dela, o menor foi 0,938.

Tabelas completas (para conferência)

As seções anteriores bastam para entender o teste. Esta parte é para conferência: traz todas as medidas calculadas, em porcentagem ou em nota de 0 a 100. O Quadro 1 explica cada uma, com o nome usado na literatura de recuperação de informação.

Quadro 1 – Medidas usadas nas tabelas completas.

Medida	O que mede	Nome técnico
1º lugar	Porcentagem de perguntas em que o primeiro resultado era o texto certo.	P@1
3 primeiros	Porcentagem dos três primeiros resultados que eram certos. Como quase toda pergunta tem um só texto certo, nem uma busca perfeita chega perto de 100%; o máximo possível aparece na última linha.	P@3
5 primeiros	Porcentagem de perguntas em que o texto certo apareceu entre os cinco primeiros resultados.	R@5
Posição	Nota de 0 a 100 pela posição do texto certo: 100 em primeiro lugar, 50 em segundo, 33,3 em terceiro; a nota final é a média.	MRR
Ordem	Nota de 0 a 100 que olha os dez primeiros resultados e dá mais crédito quando o texto certo aparece mais acima na lista.	nDCG@10
(de X a Y)	Intervalo de confiança de 95%, calculado sorteando as perguntas 10 mil vezes.	bootstrap

Tabela 3 – Todas as medidas, escolhendo entre 5 textos. Abaixo de cada número, o intervalo de confiança de 95%.

Método	1º lugar (%)	3 primeiros (%)	5 primeiros (%)	Posição (nota 0–100)	Ordem (nota 0–100)
Contagem de palavras (versão antiga)	75,0 (de 50,0 a 93,8)	31,2 (de 25,0 a 37,5)	100,0 (de 100,0 a 100,0)	83,0 (de 66,9 a 95,8)	86,9 (de 74,8 a 96,8)
BM25 (busca por palavras, usada no sistema)	81,2 (de 62,5 a 100,0)	33,3 (de 25,0 a 41,7)	100,0 (de 100,0 a 100,0)	86,1 (de 71,5 a 100,0)	89,4 (de 78,3 a 99,8)
Busca por significado, exata	68,8 (de 43,8 a 87,5)	35,4 (de 33,3 a 39,6)	100,0 (de 100,0 a 100,0)	82,3 (de 68,7 a 93,8)	84,4 (de 74,2 a 94,4)
Busca por significado, aproximada	68,8 (de 43,8 a 87,5)	29,2 (de 22,9 a 33,3)	81,2 (de 62,5 a 96,9)	78,1 (de 59,4 a 93,8)	79,7 (de 61,5 a 94,5)
Contagem + BM25 combinados	81,2 (de 62,5 a 100,0)	31,2 (de 25,0 a 37,5)	100,0 (de 100,0 a 100,0)	86,5 (de 71,9 a 100,0)	89,6 (de 78,7 a 99,7)
BM25 + significado combinados	81,2 (de 62,5 a 100,0)	33,3 (de 27,1 a 39,6)	100,0 (de 100,0 a 100,0)	88,0 (de 74,5 a 100,0)	89,0 (de 78,8 a 97,5)
Máximo possível	100,0	37,5	100,0	—	—

Tabela 4 – Todas as medidas, escolhendo entre 19 seções (só os métodos medidos nesse nível).

Método	1º lugar (%)	3 primeiros (%)	5 primeiros (%)	Posição (nota 0–100)	Ordem (nota 0–100)
Contagem de palavras (versão antiga)	56,2 (de 31,2 a 81,2)	29,2 (de 18,7 a 39,6)	71,9 (de 53,1 a 90,6)	68,9 (de 49,9 a 86,4)	70,6 (de 52,1 a 87,3)
BM25 (busca por palavras, usada no sistema)	75,0 (de 50,0 a 93,8)	35,4 (de 27,1 a 43,8)	81,2 (de 62,5 a 96,9)	81,8 (de 64,6 a 95,8)	82,9 (de 66,5 a 95,8)
Contagem + BM25 combinados	56,2 (de 31,2 a 81,2)	35,4 (de 27,1 a 43,8)	81,2 (de 62,5 a 96,9)	70,7 (de 53,0 a 86,9)	72,9 (de 55,0 a 88,3)
Máximo possível	100,0	45,8	100,0	—	—

Tabela 5 – Busca aproximada no pgvector 0.8.6, com textos artificiais (768 números cada) e 20 perguntas. As duas últimas colunas contam as perguntas cujos 10 primeiros resultados mudaram (5 reconstruções do índice; 5 ordens de inserção).

Índice	Textos	Igual à busca exata nos 10 primeiros	Mudou ao reconstruir	Mudou com outra ordem
IVFFlat como no teste: muitos grupos, só 1 consultado	1.000	47,7%	20/20	20/20
IVFFlat, configuração recomendada	1.000	100,0%	0/20	0/20
HNSW, configuração padrão	1.000	100,0%	0/20	0/20
IVFFlat como no teste: muitos grupos, só 1 consultado	5.000	36,5%	20/20	20/20
IVFFlat, configuração recomendada	5.000	100,0%	0/20	0/20
HNSW, configuração padrão	5.000	99,0%	2/20	4/20
IVFFlat como no teste: muitos grupos, só 1 consultado	20.000	25,5%	20/20	20/20
IVFFlat, configuração recomendada	20.000	100,0%	0/20	0/20
HNSW, configuração padrão	20.000	91,0%	6/20	17/20