Anexo A7 – Resultados do teste de busca

ThingIndex – Trabalho de Conclusão de Curso – Sistemas de Informação – IFPR Campus Palmas

1. O que foi testado

O autor escreveu 5 textos curtos (de lei, de contrato e de norma) e 18 perguntas sobre eles. Dessas perguntas, 16 têm resposta em um dos textos e 2 não têm resposta em nenhum. Como o próprio autor escreveu os textos, ele sabe qual é o texto certo de cada pergunta. Assim, dá para contar quantas vezes cada jeito de buscar pôs o texto certo no topo da lista. Foram testados 6 jeitos de buscar, descritos no Quadro 1. Os números são os das Seções 8.1 a 8.4 do artigo.

Quadro 1 – Os 6 jeitos de buscar testados.

Método	Como funciona
Contagem de palavras (versão antiga)	Conta quantas palavras da pergunta aparecem no texto. Era a busca da primeira versão do sistema.
BM25 (busca por palavras, usada no sistema)	Também compara palavras, mas dá mais peso às palavras raras, que dizem mais sobre o assunto. É a busca que o sistema usa hoje.
Busca por significado, exata	Um modelo de IA transforma a pergunta e cada texto numa lista de números que representa o sentido. Textos de sentido parecido ficam com números parecidos, mesmo sem palavras em comum. “Exata” quer dizer que a pergunta é comparada com todos os textos.
Busca por significado, aproximada	A mesma busca, mas os textos são separados em grupos e cada busca olha só alguns grupos. É mais rápida com muitos textos, mas pode deixar o texto certo de fora.
Contagem + BM25 combinados	Junta as listas da contagem e do BM25 numa só. Cada texto ganha pontos pela posição que teve em cada lista.
BM25 + significado combinados	Igual à anterior, mas junta o BM25 com a busca por significado exata.

2. Resultado principal

A medida principal é simples: em quantas das 16 perguntas com resposta o 1º resultado da lista era o texto certo. O teste foi feito de dois modos. “Por documento”: o método escolhe entre os 5 textos inteiros; aqui, até um sorteio acertaria cerca de 20% das vezes. “Por seção”: os textos foram divididos em 19 seções, e o método escolhe entre elas. Por seção é mais difícil (19 opções em vez de 5) e mais parecido com o que o sistema faz de verdade. A busca por significado só foi testada por documento, porque os números que representam o sentido foram calculados para o texto inteiro.

Tabela 1 – Em quantas perguntas o 1º resultado era o texto certo.

Método	Acertou o 1º resultado (por documento)	Acertou o 1º resultado (por seção)
Contagem de palavras (versão antiga)	75,0%	56,2%
BM25 (busca por palavras, usada no sistema)	81,2%	75,0%
Busca por significado, exata	68,8%	não testado
Busca por significado, aproximada	68,8%	não testado
Contagem + BM25 combinados	81,2%	56,2%
BM25 + significado combinados	81,2%	não testado

Em resumo: o BM25 foi o melhor ou empatou com o melhor nos dois modos. Por documento, acertou 81,2%, empatado com os dois métodos combinados. Por seção, acertou 75,0%, contra 56,2% da contagem de palavras; por isso o sistema trocou a contagem pelo BM25. Mas as diferenças são pequenas: por documento, 81,2% contra 75,0% é só uma pergunta a mais em 16.

3. Quando a pergunta usa outras palavras

As 16 perguntas com resposta são de três tipos: 5 usam as mesmas palavras do texto, 7 pedem a mesma coisa com outras palavras e 4 têm erros de digitação e falta de acentos. As tabelas mostram, para cada tipo, em quantas perguntas o 1º resultado era o texto certo.

Tabela 2 – Acertou o 1º resultado, por tipo de pergunta (por documento).

Método	Pergunta com as palavras do texto	Pergunta com outras palavras	Pergunta com erros de digitação
Contagem de palavras (versão antiga)	100,0%	57,1%	75,0%
BM25 (busca por palavras, usada no sistema)	100,0%	71,4%	75,0%
Busca por significado, exata	60,0%	57,1%	100,0%
Busca por significado, aproximada	60,0%	71,4%	75,0%
Contagem + BM25 combinados	100,0%	57,1%	100,0%
BM25 + significado combinados	80,0%	71,4%	100,0%

Tabela 3 – Acertou o 1º resultado, por tipo de pergunta (por seção; só os métodos testados por seção).

Método	Pergunta com as palavras do texto	Pergunta com outras palavras	Pergunta com erros de digitação
Contagem de palavras (versão antiga)	100,0%	14,3%	75,0%
BM25 (busca por palavras, usada no sistema)	100,0%	42,9%	100,0%
Contagem + BM25 combinados	100,0%	14,3%	75,0%

Em resumo: a busca por palavras acertou todas as perguntas que usam as palavras do texto (100,0%), mas caiu quando a pessoa usou outras palavras: para 57,1% na contagem e 71,4% no BM25. Por seção, a queda é maior: a contagem acertou só 14,3% dessas perguntas. A busca por significado quase não cai com outras palavras (de 60,0% para 57,1%), mas erra mais quando a pergunta usa as palavras do texto: 60,0%, contra 100,0% da busca por palavras.

4. A diferença é real ou pode ser sorte?

Com só 16 perguntas, cada pergunta vale cerca de 6% do resultado. Dois cálculos ajudam a separar uma diferença real de uma diferença por sorte. O **intervalo de confiança** é a faixa onde o resultado verdadeiro provavelmente está. Por exemplo: o BM25 acertou o 1º resultado em 81,2% das perguntas, mas o valor verdadeiro pode estar em qualquer ponto entre 62,5% e 100,0%; para a contagem de palavras (75,0%), a faixa vai de 50,0% a 93,8%. Como as duas faixas se sobrepõem, não dá para dizer qual é melhor. O **teste estatístico** calcula a chance de a diferença entre dois métodos ser só sorte. Costuma-se aceitar uma diferença como real quando essa chance fica abaixo de 5%.

Os métodos foram comparados de dois em dois, em várias medidas: 75 comparações por documento e 15 por seção. A menor chance de sorte foi 12,5% por documento e 6,2% por seção, as duas acima do limite de 5%. Quando se fazem muitas comparações, alguma sempre parece diferente por sorte; o teste então é ajustado para

ficar mais exigente, e depois do ajuste nenhuma chance ficou abaixo de 93,8%. Em nenhuma comparação mais de 8 das 16 perguntas tiveram resultado diferente entre os dois métodos.

Em resumo: com só 16 perguntas, nenhuma diferença entre os métodos pode ser considerada real. Isso não mostra que a busca por palavras seja melhor ou igual à busca por significado; mostra só que o teste é pequeno demais para ver a diferença.

5. Quando não há resposta

Em 2 das 18 perguntas, nenhum texto tem a resposta. O certo seria a busca não devolver nada. Mas os 6 métodos devolveram resultados nas 2 perguntas, ou seja, em 100,0% das vezes. Na busca por palavras, basta uma palavra em comum para o texto ganhar alguma nota. A busca por significado, aproximada, devolveu menos textos (2,5 em média, contra 5,0 dos outros métodos), porque olha só alguns grupos, mas também não deixou a lista vazia.

Uma ideia seria descartar os resultados com nota abaixo de um mínimo. Para a contagem de palavras e para o BM25, testou-se a melhor nota mínima possível. Mesmo assim, os dois ainda devolveram resultados em 1 das 2 perguntas (50,0%), porque as notas dos textos certos e dos errados se misturam. A nota mínima, portanto, ajuda pouco.

No sistema completo, quem percebe que não há resposta é o LLM, o modelo de linguagem que escreve a resposta. Ele recebe a instrução de usar só as fontes encontradas e, em todas as 14 perguntas sem resposta dos outros testes, feitas três vezes cada, disse que a informação não consta (Seção 8.2 do artigo).

Em resumo: a busca sozinha não sabe dizer “não tem”; quem diz isso é o LLM, ao escrever a resposta.

6. A busca dá sempre o mesmo resultado?

O sistema promete que a mesma pergunta traz sempre as mesmas fontes, na mesma ordem. Para conferir, cada método rodou as 18 perguntas 30 vezes, e as listas de resultados foram comparadas.

Tabela 4 – A mesma pergunta trouxe sempre a mesma lista?

Método	Deu o mesmo resultado nas 30 repetições?
Contagem de palavras (versão antiga)	Sim
BM25 (busca por palavras, usada no sistema)	Sim
Contagem + BM25 combinados	Sim
Busca por significado, exata	Sim
Busca por significado, aproximada	Não. Mudando o sorteio que forma os grupos, ou a ordem em que os textos entram, nenhuma pergunta (0%) deu sempre a mesma lista, e apareceram até 4 listas diferentes. Em média, perdeu 48,4% dos resultados da busca exata.
BM25 + significado combinados	Não testado à parte

A busca aproximada do teste usou uma configuração ruim: muitos grupos e só 1 consultado por busca. Para ver se o problema é da configuração, o teste foi repetido no pgvector, a extensão do banco de dados PostgreSQL que guarda essas listas de números, com 1.000, 5.000 e 20.000 textos artificiais e 20 perguntas. O pgvector tem dois tipos de busca aproximada: o IVFFlat, que separa os dados em grupos, e o HNSW, que liga cada item aos vizinhos mais parecidos. A Tabela 5 compara os 10 primeiros resultados de cada um com os da busca exata, e conta em quantas das 20 perguntas a lista mudou ao recriar 5 vezes o índice (a estrutura que acelera a busca) e ao inserir os dados em 5 ordens diferentes.

Tabela 5 – Busca aproximada no pgvector.

Tipo de busca	Textos	Encontrou o mesmo que a busca exata	Mudou ao reconstruir	Mudou ao trocar a ordem dos dados
IVFFlat, como no teste	1.000	47,7%	20 de 20	20 de 20
IVFFlat, configuração recomendada	1.000	100,0%	0 de 20	0 de 20
HNSW, configuração padrão	1.000	100,0%	0 de 20	0 de 20
IVFFlat, como no teste	5.000	36,5%	20 de 20	20 de 20
IVFFlat, configuração recomendada	5.000	100,0%	0 de 20	0 de 20
HNSW, configuração padrão	5.000	99,0%	2 de 20	4 de 20
IVFFlat, como no teste	20.000	25,5%	20 de 20	20 de 20
IVFFlat, configuração recomendada	20.000	100,0%	0 de 20	0 de 20
HNSW, configuração padrão	20.000	91,0%	6 de 20	17 de 20

Em resumo: a busca por palavras e a busca exata por significado deram sempre o mesmo resultado. A busca aproximada só mudou de resultado numa configuração ruim: com a configuração recomendada, o IVFFlat achou sempre o mesmo que a busca exata. O HNSW foi exato com 1.000 textos, mas com 20.000 achou 91,0% e mudou em 6 e 17 das 20 perguntas. Dar sempre o mesmo resultado, portanto, não é vantagem só da busca por palavras.

7. A origem das fontes está completa no banco?

Quando o sistema lê um documento, ele guarda no banco pedaços de vários tipos: páginas, parágrafos, trechos (os pedaços citados como fonte), itens do sumário e dados gerais do documento, como o número de parágrafos. Para cada pedaço, o banco precisa saber de onde ele veio: o documento, a página, a posição e o conteúdo. Nos 5 textos do teste, são 155 pedaços. A porcentagem com a origem completa mudou assim:

- **32,9%** (51 de 155) na primeira medição. Todos os pedaços incompletos não tinham a página.
- **45,2%** (70 de 155) depois de corrigir um defeito: a tabela de trechos não tinha a coluna da página, e ela foi criada.
- **100,0%** (155 de 155) depois de ajustar a regra da medida: os 85 dados gerais não estão em página nenhuma e passaram a dizer que vêm do documento inteiro.

Em resumo: parte da subida veio de corrigir o sistema e parte de ajustar a medida (Seção 8.4 do artigo). Como os textos do teste não têm páginas, isso mostra que o sistema grava a origem de cada pedaço, e não que a página gravada esteja certa.

8. Detalhes completos

Esta seção traz, para quem quiser conferir, todas as tabelas do teste, com todos os números convertidos para porcentagem ou para nota de 0 a 100. Aqui aparecem as siglas da área, explicadas no quadro abaixo.

Como ler as siglas

Métodos	Os mesmos 6 do Quadro 1, com os mesmos nomes.
P@1	Acertou o 1º resultado: % de perguntas em que o 1º resultado era o texto certo.
P@3	% dos 3 primeiros resultados que eram certos. Como quase toda pergunta tem um só texto certo, nem uma busca perfeita passa do “máximo possível” da última linha.
R@5	O certo apareceu entre os 5 primeiros: % de perguntas.
MRR	Nota de 0 a 100 pela posição do texto certo: em 1º lugar vale 100, em 2º vale 50, em 3º vale 33,3, e assim por diante; a nota é a média das perguntas.
nDCG@10	Nota de 0 a 100 parecida com o MRR, olhando os 10 primeiros resultados.

(de X a Y)	Intervalo de confiança de 95%: faixa onde o valor verdadeiro provavelmente está. Foi calculado sorteando as perguntas 10 mil vezes (*bootstrap*).
Pontos	Diferença entre duas porcentagens: 81,2% − 75,0% = 6,2 pontos. Positiva quando o primeiro método foi melhor.
Valor-p	Chance, em %, de a diferença ser só sorte (teste de aleatorização pareado). **Corrigido por Holm**: a mesma chance ajustada porque foram feitas muitas comparações.
Falso positivo	Devolver resultados numa pergunta que não tem resposta (100% = devolveu sempre).
Limiar	Nota mínima da própria busca; abaixo dela o resultado é descartado. Não é porcentagem e ficou como está.
***J* de Youden**	Nota de 0 a 100 de quanto o limiar separa os textos certos dos errados (100 = separa todos, 0 = igual ao acaso).
Sobreposição	% dos textos errados que tiraram nota maior que o texto certo de nota mais baixa.

Tabela D1 – Desempenho de cada método por documento (5 opções). Abaixo de cada número, o intervalo de confiança.

Método	P@1 (%)	P@3 (%)	R@5 (%)	MRR (nota 0–100)	nDCG@10 (nota 0–100)
Contagem de palavras (versão antiga)	75,0 (de 50,0 a 93,8)	31,2 (de 25,0 a 37,5)	100,0 (de 100,0 a 100,0)	83,0 (de 66,9 a 95,8)	86,9 (de 74,8 a 96,8)
BM25 (busca por palavras, usada no sistema)	81,2 (de 62,5 a 100,0)	33,3 (de 25,0 a 41,7)	100,0 (de 100,0 a 100,0)	86,1 (de 71,5 a 100,0)	89,4 (de 78,3 a 99,8)
Busca por significado, exata	68,8 (de 43,8 a 87,5)	35,4 (de 33,3 a 39,6)	100,0 (de 100,0 a 100,0)	82,3 (de 68,7 a 93,8)	84,4 (de 74,2 a 94,4)
Busca por significado, aproximada	68,8 (de 43,8 a 87,5)	29,2 (de 22,9 a 33,3)	81,2 (de 62,5 a 96,9)	78,1 (de 59,4 a 93,8)	79,7 (de 61,5 a 94,5)
Contagem + BM25 combinados	81,2 (de 62,5 a 100,0)	31,2 (de 25,0 a 37,5)	100,0 (de 100,0 a 100,0)	86,5 (de 71,9 a 100,0)	89,6 (de 78,7 a 99,7)
BM25 + significado combinados	81,2 (de 62,5 a 100,0)	33,3 (de 27,1 a 39,6)	100,0 (de 100,0 a 100,0)	88,0 (de 74,5 a 100,0)	89,0 (de 78,8 a 97,5)
Máximo possível	100,0	37,5	100,0	—	—

Tabela D2 – Desempenho por seção (19 opções). Só os métodos testados por seção.

Método	P@1 (%)	P@3 (%)	R@5 (%)	MRR (nota 0–100)	nDCG@10 (nota 0–100)
Contagem de palavras (versão antiga)	56,2 (de 31,2 a 81,2)	29,2 (de 18,7 a 39,6)	71,9 (de 53,1 a 90,6)	68,9 (de 49,9 a 86,4)	70,6 (de 52,1 a 87,3)
BM25 (busca por palavras, usada no sistema)	75,0 (de 50,0 a 93,8)	35,4 (de 27,1 a 43,8)	81,2 (de 62,5 a 96,9)	81,8 (de 64,6 a 95,8)	82,9 (de 66,5 a 95,8)
Contagem + BM25 combinados	56,2 (de 31,2 a 81,2)	35,4 (de 27,1 a 43,8)	81,2 (de 62,5 a 96,9)	70,7 (de 53,0 a 86,9)	72,9 (de 55,0 a 88,3)
Máximo possível	100,0	45,8	100,0	—	—

Tabela D3 – Acertou o 1º resultado, por tipo de pergunta (por documento).

Método	Palavras do texto (%)	Outras palavras (%)	Erros de digitação (%)	Queda com outras palavras (pontos)
Contagem de palavras (versão antiga)	100,0	57,1	75,0	+42,9
BM25 (busca por palavras, usada no sistema)	100,0	71,4	75,0	+28,6
Busca por significado, exata	60,0	57,1	100,0	+2,9
Busca por significado, aproximada	60,0	71,4	75,0	−11,4
Contagem + BM25 combinados	100,0	57,1	100,0	+42,9
BM25 + significado combinados	80,0	71,4	100,0	+8,6

Tabela D4 – Acertou o 1º resultado, por tipo de pergunta (por seção).

Método	Palavras do texto (%)	Outras palavras (%)	Erros de digitação (%)	Queda com outras palavras (pontos)
Contagem de palavras (versão antiga)	100,0	14,3	75,0	+85,7
BM25 (busca por palavras, usada no sistema)	100,0	42,9	100,0	+57,1
Contagem + BM25 combinados	100,0	14,3	75,0	+85,7

Tabela D5 – As 2 perguntas sem resposta (por documento).

Método	Falso positivo (%)	Resultados devolvidos (média)
Contagem de palavras (versão antiga)	100,0	5,0
BM25 (busca por palavras, usada no sistema)	100,0	5,0
Busca por significado, exata	100,0	5,0
Busca por significado, aproximada	100,0	2,5
Contagem + BM25 combinados	100,0	5,0
BM25 + significado combinados	100,0	5,0

Tabela D6 – As 2 perguntas sem resposta (por seção).

Método	Falso positivo (%)	Resultados devolvidos (média)
Contagem de palavras (versão antiga)	100,0	19,0
BM25 (busca por palavras, usada no sistema)	100,0	18,0
Contagem + BM25 combinados	100,0	19,0

Tabela D7 – Tentativa de usar uma nota mínima (limiar) para descartar resultados (por documento).

Método	Sobreposição (%)	Limiar (nota da busca)	*J* de Youden (nota 0–100)	Falso positivo sem limiar (%)	Falso positivo com limiar (%)
Contagem de palavras (versão antiga)	78,2	4,000	28,8	100,0	50,0
BM25 (busca por palavras, usada no sistema)	98,0	2,127	67,3	100,0	50,0

Tabela D8 – A busca por significado deu sempre a mesma lista? Uma pergunta é estável quando a lista completa, com as notas, sai idêntica em todas as repetições.

O que foi variado	Perguntas estáveis	Listas diferentes	Resultados perdidos frente à busca exata
Busca por significado, exata: repetida 30 vezes	100%	1	–
Busca por significado, aproximada: 30 sorteios diferentes dos grupos	0%	4	48,4%
Busca por significado, aproximada: textos inseridos em 30 ordens	0%	4	–
Busca por significado, aproximada: olhando de 1 grupo até todos	0%	2	–

Tabela D9 – Busca aproximada no pgvector 0.8.6, com textos artificiais (768 números cada) e 20 perguntas. As duas últimas colunas contam as perguntas cujos 10 primeiros resultados mudaram (5 reconstruções; 5 ordens).

Tipo de busca	Vetores (*N*)	Encontrou o mesmo que a busca exata nos 10 primeiros	Mudou ao reconstruir	Mudou ao trocar a ordem
IVFFlat como no teste: muitos grupos, só 1 consultado	1.000	47,7%	20/20	20/20
IVFFlat, configuração recomendada	1.000	100,0%	0/20	0/20
HNSW, configuração padrão	1.000	100,0%	0/20	0/20
IVFFlat como no teste: muitos grupos, só 1 consultado	5.000	36,5%	20/20	20/20
IVFFlat, configuração recomendada	5.000	100,0%	0/20	0/20
HNSW, configuração padrão	5.000	99,0%	2/20	4/20
IVFFlat como no teste: muitos grupos, só 1 consultado	20.000	25,5%	20/20	20/20
IVFFlat, configuração recomendada	20.000	100,0%	0/20	0/20
HNSW, configuração padrão	20.000	91,0%	6/20	17/20

Tabela D10 – Pedaços guardados no banco com a origem completa (documento, página, posição e conteúdo), na versão atual. Os dados gerais do documento não exigem página.

Tipo de pedaço	Pedaços	Com origem completa	Origem completa (%)
Trecho (o pedaço citado como fonte)	19	19	100,0
Dado geral do documento	85	85	100,0
Item do sumário	26	26	100,0
Página	5	5	100,0
Parágrafo	20	20	100,0
Total	**155**	**155**	**100,0**

Tabela D11 – As 75 comparações de dois em dois, por documento. Cada bloco compara dois métodos; as colunas são: a medida; a diferença em pontos (primeiro menos segundo método); em quantas das 16 perguntas os dois tiveram resultado diferente e, entre parênteses, em quantas cada um foi melhor; o valor-p (%); e o valor-p corrigido por Holm (%).

Contagem de palavras (versão antiga) × BM25 (busca por palavras, usada no sistema)				
P@1	−6,2	1 (0 e 1)	100,0	100,0
P@3	−2,1	3 (1 e 2)	75,0	100,0
R@5	+0,0	0 (0 e 0)	100,0	100,0
MRR	−3,1	4 (3 e 1)	100,0	100,0
nDCG@10	−2,5	5 (3 e 2)	93,8	100,0

Contagem de palavras (versão antiga) × Contagem + BM25 combinados				
P@1	−6,2	1 (0 e 1)	100,0	100,0
P@3	+0,0	2 (1 e 1)	100,0	100,0
R@5	+0,0	0 (0 e 0)	100,0	100,0
MRR	−3,4	2 (0 e 2)	50,0	100,0
nDCG@10	−2,7	4 (1 e 3)	25,0	100,0

Contagem de palavras (versão antiga) × Busca por significado, exata				
P@1	+6,2	5 (3 e 2)	100,0	100,0
P@3	−4,2	2 (0 e 2)	50,0	100,0
R@5	+0,0	0 (0 e 0)	100,0	100,0
MRR	+0,7	7 (3 e 4)	98,4	100,0
nDCG@10	+2,5	8 (4 e 4)	72,7	100,0

Contagem de palavras (versão antiga) × BM25 + significado combinados				
P@1	−6,2	3 (1 e 2)	100,0	100,0
P@3	−2,1	3 (1 e 2)	100,0	100,0
R@5	+0,0	0 (0 e 0)	100,0	100,0
MRR	−5,0	5 (2 e 3)	62,5	100,0
nDCG@10	−2,2	7 (3 e 4)	71,9	100,0

Contagem de palavras (versão antiga) × Busca por significado, aproximada				
P@1	+6,2	5 (3 e 2)	100,0	100,0
P@3	+2,1	5 (3 e 2)	75,0	100,0
R@5	+18,8	4 (4 e 0)	12,5	100,0
MRR	+4,9	7 (4 e 3)	65,6	100,0
nDCG@10	+7,1	8 (5 e 3)	49,2	100,0

BM25 (busca por palavras, usada no sistema) × Busca por significado, exata				
P@1	+12,5	6 (4 e 2)	68,8	100,0
P@3	−2,1	3 (1 e 2)	100,0	100,0
R@5	+0,0	0 (0 e 0)	100,0	100,0
MRR	+3,9	7 (4 e 3)	73,4	100,0
nDCG@10	+5,0	8 (5 e 3)	53,1	100,0

BM25 (busca por palavras, usada no sistema) × Busca por significado, aproximada				
P@1	+12,5	4 (3 e 1)	62,5	100,0
P@3	+4,2	6 (4 e 2)	40,6	100,0
R@5	+18,8	4 (4 e 0)	12,5	100,0
MRR	+8,0	6 (4 e 2)	43,8	100,0
nDCG@10	+9,6	7 (5 e 2)	31,2	100,0

BM25 (busca por palavras, usada no sistema) × Contagem + BM25 combinados				
P@1	+0,0	2 (1 e 1)	100,0	100,0
P@3	+2,1	3 (2 e 1)	75,0	100,0
R@5	+0,0	0 (0 e 0)	100,0	100,0
MRR	−0,3	4 (1 e 3)	100,0	100,0
nDCG@10	−0,2	5 (2 e 3)	100,0	100,0

BM25 (busca por palavras, usada no sistema) × BM25 + significado combinados				
P@1	+0,0	2 (1 e 1)	100,0	100,0
P@3	+0,0	2 (1 e 1)	100,0	100,0
R@5	+0,0	0 (0 e 0)	100,0	100,0
MRR	−1,9	3 (1 e 2)	75,0	100,0
nDCG@10	+0,3	5 (3 e 2)	93,8	100,0

Busca por significado, exata × Busca por significado, aproximada				
P@1	+0,0	2 (1 e 1)	100,0	100,0
P@3	+6,2	3 (3 e 0)	25,0	100,0
R@5	+18,8	4 (4 e 0)	12,5	100,0
MRR	+4,2	5 (2 e 3)	75,0	100,0
nDCG@10	+4,6	6 (2 e 4)	62,5	100,0

Busca por significado, exata × Contagem + BM25 combinados				
P@1	−12,5	4 (1 e 3)	62,5	100,0
P@3	+4,2	4 (3 e 1)	62,5	100,0
R@5	+0,0	0 (0 e 0)	100,0	100,0
MRR	−4,2	6 (3 e 3)	68,8	100,0
nDCG@10	−5,2	7 (3 e 4)	46,9	100,0

Busca por significado, exata × BM25 + significado combinados				
P@1	−12,5	4 (1 e 3)	62,5	100,0
P@3	+2,1	1 (1 e 0)	100,0	100,0
R@5	+0,0	0 (0 e 0)	100,0	100,0
MRR	−5,7	6 (2 e 4)	56,2	100,0
nDCG@10	−4,7	7 (2 e 5)	46,9	100,0

Busca por significado, aproximada × Contagem + BM25 combinados				
P@1	−12,5	6 (2 e 4)	68,8	100,0
P@3	−2,1	5 (2 e 3)	75,0	100,0
R@5	−18,8	4 (0 e 4)	12,5	100,0
MRR	−8,3	7 (3 e 4)	53,1	100,0
nDCG@10	−9,9	8 (3 e 5)	39,8	100,0

Busca por significado, aproximada × BM25 + significado combinados				
P@1	−12,5	4 (1 e 3)	62,5	100,0
P@3	−4,2	4 (1 e 3)	50,0	100,0
R@5	−18,8	4 (0 e 4)	12,5	100,0
MRR	−9,9	5 (2 e 3)	37,5	100,0
nDCG@10	−9,3	6 (3 e 3)	40,6	100,0

Contagem + BM25 combinados × BM25 + significado combinados				
P@1	+0,0	2 (1 e 1)	100,0	100,0
P@3	−2,1	5 (2 e 3)	93,8	100,0
R@5	+0,0	0 (0 e 0)	100,0	100,0
MRR	−1,6	4 (2 e 2)	87,5	100,0
nDCG@10	+0,6	6 (4 e 2)	90,6	100,0

Tabela D12 – As 15 comparações de dois em dois, por seção. Mesmo formato da tabela anterior.

Contagem de palavras (versão antiga) × BM25 (busca por palavras, usada no sistema)				
P@1	−18,8	3 (0 e 3)	25,0	100,0
P@3	−6,2	3 (0 e 3)	25,0	100,0
R@5	−9,4	2 (0 e 2)	50,0	100,0
MRR	−13,0	6 (1 e 5)	15,6	100,0
nDCG@10	−12,3	6 (1 e 5)	6,2	93,8

Contagem de palavras (versão antiga) × Contagem + BM25 combinados				
P@1	+0,0	0 (0 e 0)	100,0	100,0
P@3	−6,2	3 (0 e 3)	25,0	100,0
R@5	−9,4	2 (0 e 2)	50,0	100,0
MRR	−1,9	5 (1 e 4)	31,2	100,0
nDCG@10	−2,3	4 (1 e 3)	25,0	100,0

BM25 (busca por palavras, usada no sistema) × Contagem + BM25 combinados				
P@1	+18,8	3 (3 e 0)	25,0	100,0
P@3	+0,0	0 (0 e 0)	100,0	100,0
R@5	+0,0	0 (0 e 0)	100,0	100,0
MRR	+11,1	5 (5 e 0)	6,2	93,8
nDCG@10	+9,9	5 (5 e 0)	6,2	93,8