Anexo A8 – Correções feitas depois de medir

Depois de ver os resultados, algumas regras de correção das respostas foram ajustadas. Como isso poderia deixar os números artificialmente melhores, cada ajuste foi anotado com o motivo e o efeito. O efeito somado das três últimas correções baixou o acerto do próprio sistema de 81,7% para 69,5%.

A correção é automática: cada pergunta tem um padrão de texto que a resposta certa precisa conter e, às vezes, padrões que a tornam errada, como uma recusa. A maioria das linhas abaixo trata da bateria (Seção 8.7 do artigo), com 213 respostas sobre leis, normas e manuais públicos, escritas depois de o sistema ficar pronto. Nela, cada número aparece de dois modos: com a pergunta original (*sem expansão*) e com expansão da pergunta, em que um LLM acrescenta termos técnicos antes da busca (Seção 8.9 do artigo).

Quadro 1 – Correções que mudaram números publicados, na ordem em que foram feitas.

O que mudou	Por quê	Antes	Depois
Na correção das perguntas usadas durante o desenvolvimento (PDFs do IFPR), respostas certas escritas de outro jeito passaram a ser aceitas, e algumas perguntas ganharam mais de uma página certa.	Respostas certas eram marcadas como erradas só por usarem outras palavras, e a informação de algumas perguntas estava em mais de uma página.	Sistema sem mudanças: **204 de 216 respostas**	Sistema sem mudanças: **213 de 216 respostas**
Nas perguntas sem resposta da bateria, mais formas de recusar passaram a contar como certas (como “não consta” e “não há”).	Recusas corretas escritas de outro jeito, como “os documentos não mencionam o preço”, eram marcadas como erradas.	Produto e consumidor, original: **78,3%**	Produto e consumidor, original: **84,1%**
Na medida que confere se a página certa aparece entre as fontes, o nome de cada documento passou a ser aceito em todas as suas formas.	O sistema grava o título do documento, e a correção esperava um código. A fonte certa contava como erro quando os dois eram escritos de jeitos diferentes. Nenhuma resposta mudou de certa para errada.	Sem expansão: **37,1%** Com expansão: **53,2%**	Sem expansão: **58,1%** Com expansão: **82,3%**
Recusas (“não há informação sobre isso”) deixaram de contar como certas nas perguntas que têm resposta. Nas perguntas que trazem um dado errado, a resposta passou a ter de corrigir esse dado.	Uma resposta fixa de recusa, igual para todas as perguntas, acertaria 24 perguntas.	Sem expansão: **81,7%** Com expansão: **93,0%** Premissa falsa: **35 de 36** Valor-p da vantagem da expansão (McNemar): **0,012** Teste da Seção 8.8 do artigo: **9 de 12**	Sem expansão: **70,0%** Com expansão: **90,1%** Premissa falsa: **13 de 36** Valor-p da vantagem da expansão (McNemar): **0,0001** Teste da Seção 8.8 do artigo: **7 ou 8 de 12, conforme o braço**
Respostas que negam o assunto (“não existe”, “não consta”) ou que dizem o contrário da resposta certa também deixaram de contar como certas.	A frase “Não existe previsão sobre isso nos documentos.” acertava as 12 perguntas que perguntam se um assunto existe, e 6 recusas a uma mesma pergunta contavam como certas.	Sem expansão: **70,0%** Com expansão: **90,1%** Teste da Seção 8.7 do artigo (pares): **12 a 0**	Sem expansão: **68,5%** Com expansão: **88,7%** Teste da Seção 8.7 do artigo (pares): **13 a 0**

O que mudou	Por quê	Antes	Depois
Mais formas de recusa passaram a ser barradas, e uma resposta certa escrita “píxeis” (plural de pixel) passou a ser aceita.	“Píxeis” sem acento não contém a palavra “pixel”, e a resposta certa era marcada como errada. As outras recusas barradas não apareciam nas respostas reais.	Sem expansão: **68,5%** Com expansão: **88,7%**	Sem expansão: **69,5%** Com expansão: **88,7%**
Efeito somado das três últimas correções	Respostas que não respondem nada deixaram de contar como certas.	Sem expansão: **81,7%** Com expansão: **93,0%**	Sem expansão: **69,5%** Com expansão: **88,7%**

No teste da Seção 8.7 do artigo, que compara cada pergunta escrita com as palavras do documento com a mesma pergunta escrita com outras palavras, o gabarito original dava 8 pares a favor da primeira e 2 a favor da segunda (valor-p de 0,109, sem diferença detectável). A diferença só passou a ser detectável depois das correções deste quadro, e o artigo declara isso.

Os valores de cada linha são os do momento daquela correção; as correções seguintes e os ajustes do sistema mudaram alguns deles de novo, e o artigo publica os números finais. As regras da busca também foram ajustadas olhando as 72 perguntas usadas durante o desenvolvimento. Por isso, os números dessas perguntas não valem como teste independente; o teste de verdade é a bateria, com perguntas escritas depois.

O efeito somado das três últimas correções baixou o acerto do sistema de 81,7% para 69,5%, porque respostas que não respondiam nada deixaram de contar como certas; a última dessas três, sozinha, subiu o acerto de 68,5% para 69,5%. As outras corrigiram erros da própria correção, que marcava respostas certas como erradas; o artigo publica sempre os números de depois da última correção.