Anexo A8 – Alterações feitas depois de medir

Registro de cada alteração de gabarito ou de critério de correção feita depois de conhecidos os resultados, com o motivo e o efeito nos números.

Por que existe este registro

Para corrigir automaticamente centenas de respostas, cada pergunta dos experimentos tem um gabarito: o padrão de texto que a resposta certa precisa conter e, às vezes, padrões que a invalidam. Quando um gabarito ou um critério de correção é alterado depois de ver os resultados, existe o risco de ajustá-lo, mesmo sem querer, para que o sistema pareça melhor do que é. Por isso, cada alteração feita depois de uma medição foi anotada com a data, o motivo e o efeito nos números, inclusive as que pioraram o resultado do próprio sistema. Os números publicados no artigo são sempre os de depois da última alteração.

Quadro 1 – Termos usados neste anexo.

Termo	Significado
Gabarito	Para cada pergunta, o padrão de texto que a resposta certa precisa conter (por exemplo, o número de um artigo de lei) e, às vezes, padrões que invalidam a resposta (por exemplo, uma recusa). A correção das respostas é automática, por esses padrões. Cada revisão do gabarito ganhou um número de versão (v1, v2...).
Recusa	Resposta que diz que a informação não está nos documentos (“não consta”, “não há informação sobre isso”).
Acervo de ensino	Os 10 PDFs institucionais do IFPR, com 72 perguntas, usados durante o desenvolvimento do sistema. Cada pergunta foi feita três vezes, num total de 216 respostas.
Bateria	O teste feito depois do desenvolvimento: 71 perguntas sobre três acervos (segurança do trabalho, produto e consumidor, licitações), cada uma feita três vezes, num total de 213 respostas.
T e F	As duas formas comparadas no acervo de ensino. T (trechos): o sistema como o usuário o usa, que busca os trechos relevantes e envia só eles ao modelo de linguagem. F (documento inteiro): o modelo recebe o documento inteiro, sem busca.
C e E	As duas formas comparadas na bateria. C: a busca usa a pergunta como o usuário a escreveu. E: antes da busca, o modelo de linguagem acrescenta à pergunta termos técnicos relacionados (a *expansão da pergunta*).
Formas de pergunta	*Negativa*: a resposta não está no acervo, e o certo é recusar. *Existência*: pergunta se o acervo trata de um assunto. *Premissa falsa*: a pergunta traz um dado errado (por exemplo, uma modalidade de licitação que já não existe), e o certo é corrigir esse dado.
Literal e paráfrase	Duas versões da mesma pergunta: uma com as palavras do documento e outra com as palavras de quem não leu o documento.
Códigos das perguntas	Na bateria, lc = licitações e pr = produto e consumidor; a letra final indica a versão literal (L) ou a paráfrase (P): lc4P é a paráfrase da pergunta 4 de licitações. Sem a letra final (lc3), vale para as duas versões. No acervo de ensino, p = prosa, t = tabela e c = calendário.
Banca simulada	Revisão crítica do trabalho feita antes da defesa, simulando as perguntas de uma banca.

As alterações

Alteração 1 – Gabarito do acervo de ensino

10 a 18/09/2026

O que mudou. O gabarito do acervo de ensino passou por quatro versões (v1 a v4). Em quatro perguntas (t04, t06, c08 e c13), os padrões de texto foram afrouxados para aceitar outras redações da mesma resposta. Em outras quatro (p01, p20, p22 e t21), foram acrescentadas páginas certas.

Por quê. Respostas certas eram recusadas só porque estavam redigidas de outro modo, e a informação de algumas perguntas estava em mais de uma página.

Efeito nos números (antes → depois):

- F, que não mudou no período: 204 → 213 respostas certas de 216 (**subiu**), só pela revisão do gabarito.
- T: de 67 perguntas certas de 72 (numa só rodada, em 09/09/2026) para 216 respostas certas de 216 (**subiu**), somando ajustes no sistema e no gabarito.
- Consequência: na prática, o acervo de ensino serviu de conjunto de desenvolvimento, e não de teste (ver a última alteração).

Alteração 2 – Recusas nas perguntas negativas da bateria

19/09/2026

O que mudou. O padrão que reconhece uma recusa nas perguntas negativas da bateria foi ampliado para aceitar outras formas, como “não consta” e “não há”.

Por quê. Recusas corretas, redigidas de outro modo (por exemplo, “os documentos não mencionam o preço”), eram marcadas como erradas.

Efeito nos números (antes → depois):

- Acerto no acervo de produto e consumidor, com a pergunta original (C): 0,783 → 0,841 (**subiu**).

Alteração 3 – Nome dos documentos na medida de origem

27/09/2026

O que mudou. O gabarito da bateria passou a aceitar também as variações do título de cada documento. Essas variações ficaram fora da impressão digital (*hash*) que garante que as perguntas não mudaram.

Por quê. A medida de origem (se a página certa estava entre as fontes mostradas) comparava o título do documento citado com o identificador do gabarito, e contava erro quando os dois eram escritos de modo diferente, mesmo com o documento certo.

Efeito nos números (antes → depois):

- Origem com a pergunta original (C): 0,371 → 0,581 (**subiu**).
- Origem com a pergunta expandida (E): 0,532 → 0,823 (**subiu**).
- Nenhuma resposta mudou de certa para errada ou o contrário.

Alteração 4 – Recusas não contam mais como acerto (gabarito v4 da bateria, v2 do edital)

27/09/2026

O que mudou. Nas perguntas de existência e na lc3, uma recusa passou a invalidar a resposta. Nas de premissa falsa, a resposta passou a ter de trazer o dado que corrige a premissa. A lc3 deixou de exigir a palavra “não”. A pr2 passou a aceitar o prazo de 2 anos, que o termo de garantia também traz.

Por quê. A banca simulada mostrou que uma recusa fixa, dada a todas as perguntas, acertaria 24 perguntas de existência e de premissa falsa, e que a resposta da lc3 com a pergunta expandida (E), que estava correta, era

marcada como errada. Foi criado um teste automático que confere que recusas não contam como acerto.

Efeito nos números (antes → depois):

- Pergunta original (C): 174 → 149 respostas certas de 213, ou 0,817 → 0,700 (**caiu**).
- Pergunta expandida (E): 198 → 192 de 213, ou 0,930 → 0,901 (**caiu**).
- Premissa falsa com a pergunta original (C): 35 → 13 de 36 (**caiu**).
- Ganho da expansão da pergunta (perguntas que passaram a acertar e que deixaram de acertar com E): de 10 ganhos e 1 perda para 15 ganhos e 0 perdas; o valor-p, chance de a diferença ser acaso, foi de 0,012 para 0,0001 (a diferença ficou **mais clara**).
- Enriquecimento do índice (Seção 8.8 do artigo): 9 de 12 nos quatro braços → 7, 8, 7 e 8 de 12 (**caiu**).
- Edital municipal (acervo exploratório com um edital de concurso): sem mudança.

Alteração 5 – Respostas que negam o assunto (gabarito v5 da bateria, v3 do edital)
27/09/2026

O que mudou. Nas perguntas de existência, respostas com o verbo negado (“não existe”, “não consta”, “não trata”, “não prevê”) passaram a ser invalidadas. Na lc3, a resposta oposta à certa (“não foi revogada”, “continua em vigor”) passou a ser invalidada. A lc4 passou a exigir o art. 190 da lei ou a regra que ele estabelece, e a invalidar recusa e resposta oposta.

Por quê. A segunda leitura da banca simulada mostrou três brechas: a frase “Não existe previsão sobre isso nos documentos.” acertava as 12 perguntas de existência; “Não, a lei não foi revogada.” acertava a lc3; e as 6 respostas da lc4P, todas recusas, contavam como certas. O teste automático passou a cobrir nove recusas e as respostas opostas.

Efeito nos números (antes → depois):

- Pergunta original (C): 149 → 146 de 213, ou 0,700 → 0,685 (**caiu**).
- Pergunta expandida (E): 192 → 189 de 213, ou 0,901 → 0,887 (**caiu**).
- Só mudaram as 6 respostas da lc4P, conferidas uma a uma.
- Efeito da redação (pares literal e paráfrase em que só uma das versões acertou, a favor da literal × a favor da paráfrase): 12×0 → 13×0. Com o gabarito original (v3) eram 8×2, com valor-p 0,109, que não permitia descartar o acaso: a vantagem da pergunta literal só fica clara depois desta revisão e da anterior.
- Responder “Sim.” a tudo ainda acerta as 12 perguntas de existência, cuja resposta certa é sempre sim; o artigo declara isso.

Alteração 6 – Últimas brechas e um falso negativo (gabarito v6 da bateria, v4 do edital)
27/09/2026

O que mudou. Nas perguntas de sim ou não, recusas amplas (“não está previsto”, “nenhum dos documentos trata”, “nada consta”, “não pode ser encontrada”) passaram a ser invalidadas, assim como a resposta que começa negando o que o gabarito afirma, ou o contrário. A lc12 e a lc13 passaram a invalidar a resposta oposta. A pr8 passou a aceitar o plural “píxeis”.

Por quê. A terceira leitura da banca simulada encontrou recusas e respostas opostas que a versão anterior ainda aceitava (nenhuma delas aparecia nas respostas reais) e um falso negativo, isto é, uma resposta certa marcada como errada: “píxeis”, sem acento, não contém a palavra “pixel”.

Efeito nos números (antes → depois):

- Só a pr8L mudou: 2 respostas da pergunta original (C), de erradas para certas, conferidas.
- Pergunta original (C): 146 → 148 de 213, ou 0,685 → 0,695 (**subiu**).
- Pergunta expandida (E): sem mudança (0,887).

- Ganho da expansão (ganhos × perdas): 15×0 → 14×0 (**caiu**). Efeito da redação: 13×0 → 14×0 (**subiu**).
- Foram lidas as 30 respostas erradas restantes, uma por pergunta e braço, à procura de outras respostas certas marcadas como erradas: só a pr8 era um caso claro. A lc1P, caso de fronteira, foi mantida como estava: a resposta lista as cinco modalidades de licitação da Lei 14.133, e o gabarito, escrito antes da medição, pede também as da Lei 8.666 (“depende da lei”).

Alteração 7 – Ajustes da busca medidos no acervo de ensino

Durante o desenvolvimento

O que mudou. Regras da busca do sistema foram mantidas ou descartadas conforme o efeito medido nas 72 perguntas do acervo de ensino: exigir que a fonte contenha pelo menos 2 palavras da pergunta; procurar também a forma no plural de palavras com 6 ou mais letras; deixar de dar pontos extras a palavras do título; e levar junto o começo da página seguinte quando o texto da fonte continua nela.

Por quê. O trabalho seguiu a pesquisa em ciência do design, em que o sistema é melhorado em ciclos de construir, medir e ajustar.

Efeito nos números:

- O acerto e a origem de T no acervo de ensino foram medidos no mesmo conjunto em que o sistema foi ajustado, e por isso não valem como teste independente.
- As perguntas da bateria, escritas depois, são o conjunto de teste.